

苏州大学

本科毕业设计(论文)

学院(部) 未来科学与工程学院

题 目 基于扩散模型的古汉字修复方法研究

年 级 2022 级 专业 人工智能

班 级 二班 学号 2262404035

姓 名 巴瑶涵

指导老师 王进 职称 教授

论文提交日期 2026 年 4 月 20 日

苏州大学
本科毕业设计（论文）独创性声明

本人郑重声明：所提交的本科毕业设计（论文）是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本设计（论文）不含其他个人或集体已经发表或撰写过的研究成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人承担本声明的法律责任。

作者签名： 巴瑶涵 日 期： 2026. 4. 20

苏州大学

本科毕业设计（论文）使用授权声明

本人完全了解苏州大学关于收集、保存和使用本科毕业设计（论文）的规定，即：本科毕业设计（论文）的著作权以及文中研究成果的知识产权归属苏州大学。苏州大学有权向国家有关部门或第三方机构送交毕业设计（论文）的复印件和电子文档，允许毕业设计（论文）被查阅和借阅，可以采用影印、缩印或其他复制手段保存和汇编毕业设计（论文），可以将毕业设计（论文）的全部或部分内容编入有关数据库进行检索。

涉密设计（论文）☐

本设计（论文）属 _____ 在 _____ 年 _____ 月解密后适用本规定。

非涉密设计（论文）☒

论文作者签名： 巴瑞涵 日 期： 2026.4.20

导 师 签 名： 1 日 期： 2026.4.20

基于扩散模型的古汉字修复方法研究

摘 要

古汉字作为中华文明的重要载体，其修复工作对于文化遗产保护具有重要意义。然而，真实古籍修复场景面临多重挑战：碑文易受风化、水蚀及盐碱侵蚀而残缺模糊，碑拓存在墨色不均、笔画粘连与细节丢失等问题，纸质古籍则常伴随水渍、霉斑、虫蛀与老化脆化等损伤，尤其针对大面积侵蚀痕迹覆盖的古籍文字，修复难度更为突出。受此影响，可用古籍样本普遍存在严重侵蚀痕迹，加之历史侵蚀损伤具有不可逆性，真实场景中难以获取残缺字形与对应干净字形的配对训练数据；同时不同碑文风格差异显著，同一碑文内同风格可用字体样本稀少，进一步加剧了古汉字智能修复的难度。针对上述问题，本文开展基于扩散模型的古汉字修复方法研究，重点面向大面积侵蚀痕迹覆盖的古籍文字修复场景，提出针对性解决方案。首先，构建了面向古汉字修复的专用数据集，基于多种书法风格及对应的常用汉字的基础数据生成三种不同侵蚀程度的退化样本，并设计风格与字符均未见（SFUC）、风格未见字符已见（UFSC）和风格已见字符未见（UFUC）三类泛化测试场景，系统评估模型在不同分布条件下的泛化能力。在方法上，从分布建模角度出发，将古汉字修复问题形式化为“风格分布与退化噪声分布的解耦问题”，提出一种两阶段扩散修复框架。该方法先通过条件扩散模型对退化图像进行去噪处理，获得结构完整且噪声受控的干净风格参考；再在扩散生成过程中融合风格编码与内容编码特征，实现目标汉字的结构精准重建与书法风格有效迁移。实验结果表明，与现有最优字体生成方法相比，本文方法在侵蚀面积大于60%的测试集上将FID从81.483降至14.204，LPIPS从0.2841降至0.1476，综合性能全面领先。同时，消融实验进一步验证了侵蚀痕迹去噪模块在稳定风格特征建模、提升修复效果中的关键作用。综上，本文方法能够在复杂退化条件下，尤其是大面积侵蚀场景中，有效平衡古汉字的结构恢复与风格一致性要求，为真实古籍修复提供了一种具有实际应用潜力的智能化解决方案，也为书法风格生成技术在文物数字化保护与数字活化领域的落地应用提供了参考。

关键词：古汉字修复；扩散模型；书法风格生成；图像去噪

Research on Restoration Methods for Ancient Chinese Characters Based on Diffusion Models

Abstract

As an important carrier of Chinese civilization, restoration of ancient Chinese characters is of great significance to cultural heritage protection. However, restoration faces severe challenges: stone inscriptions are eroded by weathering, water and salt; rubbings suffer from uneven ink and detail loss; paper documents are damaged by water stains, mildew, worms and aging. Restoration of characters with large-area erosion is particularly challenging. These lead to severe degradation of available samples. Irreversible historical erosion makes it difficult to obtain paired training data of incomplete and clean characters, and large style variation among inscriptions with limited samples increases difficulty. To address these issues, focusing on restoring characters with large-area erosion, this paper proposes a diffusion-based restoration method. We construct a dataset with three degradation levels and design three generalization test settings. We formulate restoration as decoupling style distribution from degradation noise, and present a two-stage diffusion framework. It first denoises degraded samples to obtain clean style references via a conditional diffusion model, then fuses style and content encodings to achieve accurate structure reconstruction and valid style transfer. Experiments show our method significantly outperforms state-of-the-art font generation methods on the test set with erosion area $>60\%$, reducing FID from 81.483 to 14.204 and LPIPS from 0.28411 to 0.14763. Ablation studies verify the effectiveness of the erosion denoising module in stabilizing style modeling and improving restoration quality. Overall, our method achieves better balance between structure recovery and style consistency, especially in complex degradation scenarios with large-area erosion, providing a practical intelligent solution for real ancient document restoration and supporting digital preservation and activation of cultural heritage.

Keywords: Ancient Chinese Character Restoration; Diffusion Model; Calligraphy Style Generation; Image Denoising

目 录

前 言	1
第 1 章 绪论	2
1.1 研究背景与意义	2
1.2 相关工作	3
1.2.1 古汉字图像修复方法	3
1.2.2 书法风格生成方法	4
1.2.3 扩散模型在书法生成中的应用研究	5
1.2.4 古籍汉字数据集	6
1.2.5 小结	7
1.3 亟待解决的问题	8
1.4 本文主要工作	8
1.5 论文结构安排	9
第 2 章 相关背景知识	11
2.1 扩散模型概述	11
2.2 条件扩散模型与图像修复应用	12
2.3 书法风格生成基本概念	13
2.4 本章小结	14
第 3 章 古籍汉字专用数据集构建	15
3.1 数据集构成	15
3.2 数据来源与处理方式	16
3.2.1 TTF 渲染数据	16
3.2.2 真实碑帖图像	16

3.3 侵蚀痕迹模拟	18
3.4 本章小结	21
第 4 章 基于扩散模型的古汉字修复框架	22
4.1 整体修复框架设计	22
4.2 侵蚀痕迹去噪模块	23
4.2.1 前向扩散过程	23
4.2.2 条件反向去噪过程	24
4.2.3 网络结构设计	24
4.2.4 损失函数设计	25
4.3 风格生成模块	25
第 5 章 实验设计与结果分析	28
5.1 实验环境与参数设置	28
5.1.1 实验环境配置	28
5.1.2 实验数据设置	28
5.1.3 参数设置	29
5.2 评价指标	29
5.3 侵蚀痕迹去噪模块效果分析	31
5.4 多场景泛化性能对比实验	32
5.5 消融实验	36
5.6 补充定性分析	38
5.7 任务泛化性实验	39
5.8 可视化交互界面展示	40
第 6 章 总结与展望	42
6.1 主要研究工作总结	42

6.2 研究局限性分析	43
6.3 未来研究方向展望	44
参考文献	45
致 谢	49

前 言

古籍是中华文明延续数千年的重要载体，其中保存的汉字不仅记录了历史信息，更凝结了历代书家的书写风格与审美意趣。然而，受保存环境、时间侵蚀等因素影响，大量古籍出现了虫蛀、水渍、墨迹褪色、碑刻漫漶等不可逆的退化损伤。当汉字笔画因侵蚀而残缺不全时，其中的文化信息便面临永久失传的风险。传统手工修复依赖专业人员逐字处理，周期长、成本高，难以应对海量古籍的规模化保护需求。

近年来，计算机视觉与深度学习技术的发展为古籍数字化修复提供了新的可能。现有方法主要分为两类：一类是基于局部补全的直接修复方法，通过去噪、形态学补全和像素级填充等方式修补残损笔画；另一类是基于风格迁移的临摹式修复方法，借助同一古籍中的完好字符进行风格引导，实现残损字符的重建。然而，真实古籍场景对这两类方法均提出了严峻挑战：一方面，古籍多为孤本或存世量有限，同时古籍汉字的侵蚀具有不可逆性，难以获得大规模“破损—完整”配对数据；另一方面，风格迁移方法所需的风格参考区域本身常伴随褪色、污渍和模糊等退化现象，属于不完美弱参考。现有方法大多假设风格参考清晰完整，直接将退化图像输入模型，容易将噪声误当作风格特征加以学习，导致修复结果失真。

本文研究方法面向受大范围侵蚀的古籍文字，选用基于风格迁移的修复方法，以“退化风格参考条件下的古籍汉字修复”为研究对象，从风格分布与退化噪声分布解耦的视角出发，探索一种能够在退化条件下稳定提取风格信息并精准重建字符结构的修复框架。本文的主要研究工作包括：

- （1）构建了涵盖多种书法风格以及对应常用汉字、三种难度等级侵蚀样本的古籍汉字修复专用数据集；
- （2）提出了基于分布解耦的两阶段扩散修复框架；
- （3）设计了面向多泛化场景与多侵蚀程度的系统评测方案，采用多维度指标与消融实验验证方法有效性。

本文的研究成果有望为文博机构、图书馆等单位的古籍数字化工作提供一定的技术参考，在缓解人工修复压力、提升重度侵蚀古籍修复效率方面进行初步探索，也可作为书法风格生成技术在古籍数字活化中的应用提供一点基础。

第1章 绪论

本章首先阐述古籍汉字修复的研究背景与意义，分析现有方法的不足与亟待解决的问题；其次，从古汉字图像修复方法、书法风格生成方法、扩散模型应用及古籍汉字数据集四个方面梳理国内外研究现状；最后，介绍本文的主要工作与论文结构安排。

1.1 研究背景与意义

中华古籍汉字是传承历史文明、记录文化演进与学术脉络的重要载体，兼具珍贵的文物价值与历史研究价值。我国现存古籍文献体量庞大，但受长期保存条件限制，许多古籍存在不同程度的退化损伤：纸质文献常见虫蛀穿孔、水渍晕染与墨迹褪色，碑刻石质文献则面临剥落、漫漶与表面坑蚀等侵蚀问题^[1]（如图 1.1 所示）。这些退化导致汉字笔画残缺、字迹漫漶，部分珍贵文献的核心文化信息面临永久失传的风险，古籍汉字的系统性修复与数字化保护工作已刻不容缓。



图 1.1：真实古籍碑文侵蚀痕迹

传统古籍汉字修复主要依赖专业人员手工完成，存在周期长、效率低、成本高且易对原件造成二次损伤等不足，难以满足海量古籍资源的规模化保护需求。随着计算机视觉与深度学习技术的发展，智能修复逐渐成为古籍数字化保护的重要方向。现有方法主要包括两类：一类是基于局部补全的直接修复方法，通过去噪、形态学补全和像素级填充等方式直接修补残损笔画；另一类是基于风格迁移的临摹式修复方法，借助同一古籍中的完好字符进行风格引导，实现残损字符的重建。然而，真实古籍场景对这两类方法均提出了严峻挑战：一方面，古籍多为孤本或存世量有限，难以获得大规模“破损—完整”配对数据；另一方面，风格参考区域本身常伴随褪色、污渍和模糊等退化现象，属于不完美弱参考；当字符侵蚀严重、结构信息大量缺失时，现有方

法往往难以兼顾内容恢复与风格一致性，因而难以直接适用于真实古籍修复任务^[2-3]。

由此可见，真实古籍修复的关键难点在于：在配对样本稀缺、参考区域退化以及字符结构严重缺失等约束条件下，如何实现内容恢复与风格统一。尤其对于大面积侵蚀或遮盖导致关键笔画大量缺失的古籍汉字，字符自身可提供的结构信息已十分有限，难以仅依赖局部补全、形态学修复或普通图像去噪方法完成有效恢复。此时，修复过程往往需要借助同一古籍中其他相对完好字符所提供的书写风格信息，对目标字符进行基于风格引导的临摹式重建。因此，本文围绕退化风格参考条件下的古籍汉字修复展开研究，将该问题视为弱参考条件下内容重建与风格生成相结合的修复任务。现有书法风格生成方法通常假设风格参考图像清晰且完整，而真实古籍中用于提供风格信息的参考区域往往伴随侵蚀、模糊等退化噪声，直接应用现有方法容易将噪声误建模为风格特征，从而影响修复结果的风格一致性与结构稳定性。为此，本文从风格分布与退化噪声分布解耦的视角出发，探索一种能够在退化条件下稳定提取风格信息并精准重建字符结构的古籍汉字修复方法。

本研究的意义主要体现在两个方面：在方法层面，针对大面积侵蚀场景下传统直接补全方法难以有效恢复字符结构的问题，本文引入两阶段扩散建模，对风格信息与退化噪声进行显式分离，为弱参考条件下基于风格引导的古汉字临摹式修复提供了一种可行的技术思路；在应用层面，研究成果未来可尝试应用于文博机构、图书馆等单位的古籍数字化工作，有望缓解人工修复压力、缩短修复周期，并提升重度侵蚀古籍的修复效率与质量。同时，该研究可为古籍文化研究、数字化传播与资源共享提供更高质量的数据支撑，也可为书法风格生成技术在古籍数字活化中的应用探索提供基础。

1.2 相关工作

1.2.1 古汉字图像修复方法

古汉字修复旨在恢复受损字符的结构完整性与视觉可读性，是文物数字化保护中的重要研究方向。早期方法主要基于传统图像处理技术，如插值、纹理合成与稀疏表示等，通过局部像素填补实现修复。其中，插值方法仅适用于极小范围的微小破损，面对稍大面积的残缺字迹，修复效果急剧恶化，无法保证笔画连贯性^[4]；纹理合成方

法仅追求局部视觉相似性，忽略汉字严谨的间架结构与笔画逻辑，修复后极易出现字形扭曲^[5]；稀疏表示方法高度依赖预设字典的质量与覆盖度，难以适配古籍中多样的书法流派与书写风格，泛化能力较差。这类方法仅聚焦图像底层视觉特征，不具备汉字语义结构与书法风格的建模能力，无法满足古籍修复的核心要求。

随着深度学习技术的初步应用，基于“编码器—解码器”结构、生成对抗网络的早期深度生成模型，逐步成为古汉字修复的主流方向，实现了从像素填补到语义级生成的跨越。基于卷积神经网络的“编码器—解码器”模型，通过端到端学习生成语义合理的修复结果，但依赖像素级损失函数训练，生成字迹普遍纹理模糊、笔画细节缺失，风格保真度不足^[6-7]。后续生成对抗网络（Generative Adversarial Network, GAN^[8]）借助对抗训练机制，大幅提升修复图像的视觉真实感，cGAN^[9-10]、CycleGAN^[11-12]等模型也被应用于残缺字符复原与字体风格迁移任务。但这类模型通常依赖风格统一、标注完备的大规模数据集训练，而真实古籍修复场景常面临数据稀缺、风格参考样本受损等问题；尤其当风格参考图像存在侵蚀、模糊等退化噪声时，现有方法缺乏针对性建模机制，易将噪声误建模为风格特征，影响生成结果的稳定性与风格一致性。

近年来，随着图像修复任务的发展，部分研究进一步从结构建模与多尺度特征融合角度提升修复效果。例如，Luo 等人^[13]提出的 MFNet 通过多尺度特征融合机制增强字符缺失区域的结构恢复能力；Mao 等人^[14]提出的 ALDII 方法通过自适应学习策略，有效提升了复杂文档退化区域的修复性能。这类方法在结构恢复与细节补全方面取得一定进展，但本质仍属于受损图像直接修复范式，以恢复原始字符为目标，而非在给定风格约束下生成新的目标字符。

尽管上述方法在轻度退化条件下展现出较为稳定的效果，但存在对严重结构缺失适应性不足的问题，难以满足大面积侵蚀场景下的修复需求，因此需借助生成式模型并结合书法风格信息进行结构重建。

1.2.2 书法风格生成方法

与侧重破损区域填补和图像去噪的古汉字修复方法不同，书法风格生成方法更关注书写风格的建模与迁移。当字符笔画结构信息缺失时，仅依靠局部修补通常难以恢复完整字形，需要借助同一文献中其他字符的风格信息对目标字符进行生成式重建。

该类方法旨在兼顾字符结构合理性与风格一致性。相关研究通过机器学习方法实现书法风格的建模与再现，目前形成两条互补技术路径：字符风格生成与篇章风格生成，分别适配古籍单字破损修复与整页文档修复场景。

字符风格生成以保持字符语义与结构稳定为前提，实现书法风格的迁移与重构，可适配古籍单字破损的常见修复场景，是目前古籍汉字修复的核心技术参考方向。早期研究侧重字符内部局部细节的一致性，Park 等人^[15]提出的 LF-Font 通过局部化风格表示和风格因式分解机制，提升少样本字体生成精度，更好地捕捉笔画层面的风格差异；Tang 等人^[16]提出的 FS-Font，在有限样本条件下可保持较好的结构一致性和风格表达能力。另一部分研究从结构表达能力与生成框架角度改进，Wang 等人^[17]提出的 CF-Font 通过内容融合机制实现内容与风格的解耦建模，为字体生成提供统一的内容——风格建模框架；Chen 等人^[18]提出的 IF-Font 引入表意文字描述序列，结合多尺度特征交互机制，提升模型对字符结构及其长期依赖关系的建模能力。在此基础上，Yao 等人^[19]提出的 VQ-Font 通过向量量化机制将字体表示映射到离散潜空间，结合结构感知增强策略，提升复杂字形的结构表达能力与生成稳定性；Chen 等人^[20]提出的 DA-Font 则通过部件级分解、双注意力机制及混合集成，进一步提升复杂字形的结构一致性，这些工作为古籍修复中少样本风格学习与复杂字形还原提供了技术基础。

篇章风格生成关注多个字符在空间布局、结构连续性及整体风格一致性上的统一建模，适配整页、整段古籍文本的批量修复任务，相关研究主要从长文本图像生成、篇章布局控制及手写/书法场景全局风格建模等角度展开，例如 TextDiffuser-2^[21]、Qwen-Image^[22]、Mayr 等人^[23]提出的段落级手写模仿方法及 Xu 等人^[24]提出的 UniCalli 等。相较于字符级方法，篇章级方法更强调全局结构控制与长程依赖关系建模。由于本文重点聚焦单字残缺条件下的精细化修复，因此技术路线主要采用字符风格生成方法，篇章级研究仅作为相关背景参考。

现有书法风格生成方法普遍假设风格参考图像干净无退化，这一假设在真实古籍场景中难以成立，模型易将退化噪声误建模为风格特征，影响生成稳定性。

1.2.3 扩散模型在书法生成中的应用研究

扩散模型近年来在图像生成领域取得突破性进展，Ho 等人提出的去噪扩散概率

模型（Denoising Diffusion Probabilistic Models, DDPM^[25]）模型通过逐步去噪实现高质量生成，稳定性与多样性优于 GAN 模型；Saharia 等人^[26]提出的 SR3 模型进一步验证了扩散模型在图像重建与细节恢复方面的优势。在图像修复领域，扩散模型已被广泛应用于结构恢复与图像补全任务，在复杂结构的建模方面展现出优越的性能^[27]。

在古汉字图像修复这一细分场景中，Li 等人^[2]提出的 DiffACR 基于冷扩散模型（Cold Diffusion^[28]）框架将腐蚀图像的合成建模为退化过程，有效避免了合成掩码与真实腐蚀分布不匹配的问题。

在字体生成方向，Yang 等人^[29]提出的 FontDiffuser 将扩散模型引入书法风格生成，通过多尺度特征融合与风格对比学习显著提升生成质量。尽管扩散模型在生成质量上具有显著优势，但现有方法仍基于理想条件，假设风格参考图像干净无退化。在真实古籍修复场景中，风格参考往往伴随侵蚀、模糊等退化噪声，导致“风格分布”与“退化噪声分布”相互耦合，大幅增加建模难度。因此，如何在扩散模型框架下实现二者有效解耦，成为当前研究的重要方向。

1.2.4 古籍汉字数据集

现有古籍汉字相关的公开数据集根据其任务目标与数据形式，大致可分为通用基准数据集与专用修复数据集两类。本文从是否包含成对退化样本这一关键特征出发，对相关数据集进行梳理。

通用基准数据集主要面向风格分类、字体生成或文档分析等任务，通常不包含成对退化样本。其中，书法风格类数据集多以单字图像为基本单位：Zhao 等人^[30]提出了 MCCD，该数据集包含 329715 个单字图像，并标注了字体风格、朝代和书家等多维属性信息，为书法风格识别与作者鉴别提供了数据基础；Zhang 等人^[31]提出了 MegaHan97K 数据集，该数据集包含 97455 个汉字类别、总样本数超过 460 万，为大规模汉字识别与零样本学习提供了评测平台。文档分析类数据集则面向文档级理解任务，包含整页或多字符图像：Shi 等人^[32]提出了 M5HisDoc，这是首个面向多风格中国历史文档分析的基准数据集，包含大量真实古籍页面图像及细粒度标注，支持文档增强、文本检测与识别等多项任务。

专用修复数据集近年来逐渐受到关注，其核心特征是引入成对完好—缺损图像，

以支撑修复任务的训练与评测。Zhu 等人^[33]提出了 CIRI 数据集，该数据集面向碑拓文本恢复任务，包含多种书法风格与复杂文字结构的碑拓图像，并通过合成退化生成“完好—缺损”样本，用于文本检测、识别与恢复任务的评测。Li 等人^[2]提出了 ARMCD 数据集，该数据集从多种古代碑拓与手稿资料中收集未侵蚀与真实侵蚀的古汉字单字符图像，并通过从真实侵蚀样本中提取或合成侵蚀掩膜叠加到未侵蚀图像上，构建贴近真实退化过程的“干净—退化”成对样本，为古汉字修复方法的研究提供了数据基础。尽管专用修复数据集在成对样本构建方面迈出了重要一步，但现有数据集总体规模仍较有限，对退化强度、风格多样性及泛化场景的覆盖仍不充分，难以系统支撑复杂退化条件下的古汉字修复研究。

1.2.5 小结

现有研究在古汉字修复方法、书法风格生成及相关数据资源构建方面已取得一定进展：传统基于卷积网络与生成对抗网络的方法，在结构恢复与视觉真实感方面具有一定优势；基于扩散模型的生成方法，在细节表达与生成稳定性方面展现出更强潜力；字符级与篇章级风格生成方法为不同粒度的古籍修复任务提供技术支撑；多样化数据集的构建则为模型训练与评测奠定基础。

但现有研究在真实古籍修复场景中的适用性仍存在不足：方法层面，多数工作基于理想或干净的风格参考条件，未充分考虑风格图像中普遍存在的侵蚀、模糊与噪声干扰，导致模型在实际应用中易将退化噪声误建模为风格特征，从而影响生成结果的稳定性与一致性；数据层面，尽管已有部分专用修复数据集引入成对退化样本，但整体规模和多样性仍较为有限，难以覆盖真实古籍中复杂多变的退化形式，这对模型在高退化条件下的泛化能力构成了较大挑战。

因此，如何在退化条件下实现“结构信息”与“风格信息”的有效分离建模，成为古汉字修复任务的关键问题。针对上述挑战，本文以扩散模型为基础框架，结合真实古籍中风格参考图像存在退化噪声的特点，提出一种基于分布解耦的两阶段古汉字修复方法：先通过侵蚀痕迹去噪获得稳定风格参考，再在扩散生成过程中实现风格与内容的融合建模，从而提升复杂退化场景下的修复效果与风格一致性。

1.3 亟待解决的问题

在真实古籍修复场景中，风格参考图像往往同时包含书法风格信息与侵蚀、模糊、污渍等退化噪声，二者在像素空间中相互混杂，导致模型难以区分真实风格特征与退化干扰，并易将噪声误建模为风格特征，从而影响生成结果的稳定性与风格一致性。基于真实古籍修复需求，现有研究仍存在以下不足：

数据集结构与任务需求仍存在差距：现有公开数据集多面向字体生成、书法风格分类或文档分析任务，专用于古汉字修复的数据集在规模与结构上仍较为有限。现有数据通常仅提供单一维度信息，如不同书法风格样本或“干净—退化”配对图像，缺乏同时覆盖“书法风格—字符类别—退化程度”的多维数据结构。尤其缺少在同一书法风格下提供统一字符集合，并对侵蚀类型与程度进行系统建模的配对数据，难以刻画真实古籍中字迹退化的复杂性，从而限制模型在复杂退化场景下的学习能力。

修复方法与真实场景存在差距：现有书法风格生成方法大多假设风格参考图像清晰完整，并据此进行风格迁移或字符生成。然而在真实古籍修复中，风格参考区域往往伴随侵蚀、模糊或污渍等退化现象，使得风格特征本身受到噪声干扰。由于缺乏针对退化参考样本的专门设计，现有方法难以稳定提取可靠风格信息，从而影响生成结果的结构稳定性与风格一致性。

评测方式与实际应用场景存在偏差：现有方法的实验评测通常基于干净或理想化数据，缺乏在真实退化条件下的系统评估。特别是缺少针对不同侵蚀程度及不同泛化条件的统一评测方案，使得实验结果难以全面反映模型在实际古籍修复任务中的表现。

上述问题从本质上反映了古汉字修复任务中风格分布与退化分布耦合建模的困难。因此，有必要从分布建模角度出发，对风格信息与退化噪声进行显式分离，以提升模型在复杂退化条件下的稳定性与泛化能力。

1.4 本文主要工作

针对上述问题，本文从分布解耦角度出发，将古汉字修复建模为风格信息与退化噪声的分离问题，并围绕数据集构建、方法设计与评测方案开展研究，主要工作如下：

构建古汉字修复专用数据集：本文构建了一个面向古汉字修复任务的专用数据集，

该数据集涵盖 120 种书法风格和 1200 个常用汉字，其中训练集包括从中随机抽取的 107 种书法风格和对应的 800 常见汉字，测试集被划分为风格与字符均未见（Seen Font Unseen Character, SFUC）、风格未见字符已见（Unseen Font Seen Character, UFSC）和风格已见字符未见（Unseen Font Unseen Character, UFUC）三种泛化场景，对于该数据集中的所有基础图像，本文并通过侵蚀模拟生成 easy、medium、hard 三个难度等级的成对图像。

提出基于分布解耦的两阶段古汉字修复框架：针对风格参考图像中存在退化噪声的问题，本文首先通过侵蚀痕迹去噪模块对退化图像进行结构恢复，以获得噪声受控的风格参考；随后在扩散生成框架下，通过风格与内容的解耦建模，实现目标字符的生成。该方法通过任务分解避免了噪声对风格建模的干扰，从而提升生成稳定性与风格一致性。

设计贴近真实场景的评测方案：在构建的数据集基础上，本文采用 FID、L1、SSIM 和 LPIPS 等指标对模型性能进行系统评估，并在不同侵蚀难度和泛化场景下测试模型的修复能力。同时通过消融实验分析各模块对最终修复效果的贡献，以验证所提出方法的有效性。

搭建基于 Streamlit 的可视化交互界面：封装了所提出的两阶段扩散修复模型。用户可通过图形化界面完成风格图片选择、侵蚀去噪与风格迁移生成的完整操作流程，并实时查看修复结果。该界面直观展示了本文方法在复杂退化条件下的结构保持与风格表达能力，为古汉字修复技术的应用演示与后续研究提供了便捷的交互工具。

综合来看，本文的主要创新体现在数据与方法两个层面：在数据层面，构建了一个面向古汉字修复任务的专用数据集，并设计了多种泛化测试场景，为模型在不同分布条件下的性能评估提供了系统化基准；在方法层面，从分布建模角度出发，将古汉字修复问题形式化为“风格分布与退化噪声分布的解耦问题”，并通过两阶段扩散建模实现对二者的显式分离，从而在复杂退化条件下提升模型的稳定性与泛化能力。上述研究为复杂退化条件下的古汉字修复提供了一种具有良好泛化能力的解决思路。

1.5 论文结构安排

本文共分六章，结构安排如下：

第一章阐述研究背景与意义，梳理传统修复方法、书法风格生成技术及古籍汉字数据集的国内外研究现状，指出现有研究的不足，并介绍本文主要工作。

第二章介绍扩散模型的基本原理、条件扩散模型在图像修复中的一般应用范式以及字体风格迁移任务的基本概念，为后续方法设计提供技术背景。

第三章介绍古籍汉字专用数据集的构建，包括数据集的构成与规模、数据来源与处理方式，重点阐述侵蚀痕迹的模拟方法与难度分级，以及测试集的泛化场景划分。

第四章提出基于扩散模型的两阶段修复框架，分别介绍前置去噪模块与风格迁移生成模块的设计思路，并说明两模块串联推理的测试流程。

第五章展示实验设计与结果分析，介绍实验设置与评价指标，在三种泛化场景下进行对比实验与消融实验，通过可视化结果分析模型性能，验证方法的有效性。

第六章总结本文的主要工作，分析研究的局限性，并展望未来研究方向。

第 2 章 相关背景知识

本章介绍本文方法所涉及的核心技术背景，为后续章节的方法设计与实验分析提供必要的概念基础。首先概述扩散模型的基本思想与工作流程；其次介绍条件扩散模型及其在图像修复任务中的一般应用方式；最后简要说明字体风格迁移任务的基本定义与常见建模思路。

2.1 扩散模型概述

扩散模型（Diffusion Model）是一类近年来受到广泛关注的深度生成模型，其核心思想受非平衡热力学的扩散过程启发。与生成对抗网络从随机噪声直接生成图像的方式不同，扩散模型采用“先破坏、再重建”的两阶段策略：先通过一个固定的前向过程向真实图像逐步添加噪声，直至图像退化为完全的随机噪声；随后训练一个神经网络学习该过程的逆过程，从噪声中逐步恢复原始清晰图像。本文采用去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM^[25]）作为扩散模型的具体实现。




图 2.1: DDPM 原理图

如图 2.1 所示，DDPM 可以表示为一个马尔可夫链结构，其中各状态变量记为 $x_1, x_2, \dots, x_T$ 。这里， x_0 表示真实数据分布中的样本，而 x_T 表示经过多步加噪后接近高斯分布的纯噪声。中间状态则表示在第 t 步的带噪图像。前向扩散过程由条件分布 $q(x_t | x_{t-1})$ 描述，其作用是在每一步向图像中注入少量高斯噪声，使数据逐渐丧失原有结构信息。该过程是预先设定的，不包含可学习参数。与之相对应，反向去噪过程由参数化分布 $p_\theta(x_{t-1} | x_t)$ 表示，其目标是在给定当前带噪样本 x_t 的条件下，预测更接近原始数据的上一时刻状态 x_{t-1} 。通过逐步迭代该过程，模型能够从初始噪声 $x_T \sim \mathcal{N}(0, I)$ 出发，最终生成符合数据分布的样本 x_0 。

前向扩散过程是一个不包含可学习参数的马尔可夫链。在每一时间步，向当前图像添加微量高斯噪声，经过数百至上千步的累积后，原始图像的结构信息被逐渐破坏，最终转化为近似各向同性高斯分布的随机噪声。该过程为后续反向建模提供了不同噪声强度下的训练样本。反向去噪过程是扩散模型的学习核心，同样建模为一个马尔可夫链。神经网络通过学习 $p_{\theta}(x_{t-1}|x_t)$ 来逐步去除噪声成分，实现从噪声到数据的重建。实际应用中，反向过程通常采用 U-Net 结构进行建模，利用其多尺度特征提取与跳跃连接机制，在去噪过程中有效恢复图像的细节结构与空间信息。

与生成对抗网络和变分自编码器等生成模型相比，扩散模型具有训练稳定性高、不易出现模式崩塌以及生成样本多样性强等优点，在图像生成、图像修复和图像超分辨率等任务中展现出良好的性能。

2.2 条件扩散模型与图像修复应用

无条件扩散模型仅依赖数据分布进行建模，其生成结果具有较强的随机性，难以对生成内容施加有效约束。为增强生成过程的可控性，条件扩散模型在反向去噪过程中引入额外的条件信息，引导生成过程朝满足特定约束的方向演化。

条件信息的形式具有多样性，可包括类别标签、文本描述、语义分割图、边缘图、深度图或引导图像等。在建模过程中，条件变量通常与当前噪声状态共同输入模型，使网络在逐步去噪过程中持续融合条件约束，从而提升生成结果的结构一致性与语义准确性。从实现方式上看，条件信息既可以通过通道拼接、特征融合等显式方式注入网络，也可以通过交叉注意力等机制参与特征交互，使模型在不同尺度上利用条件信息对生成过程进行调控。相比传统生成模型一次性输出结果的方式，条件扩散模型通过多步迭代逐渐细化图像内容，更有利于在复杂场景下恢复局部细节与整体结构。

在图像修复任务中，常将退化图像作为条件输入。模型在每一步去噪过程中，同时接收当前带噪图像与对应的条件信息，通过利用退化图像中残存的结构线索，对缺失或损坏区域进行逐步重建。该过程本质上是在条件约束下对数据分布进行重建，从而实现目标图像的恢复。

需要注意的是，条件扩散模型的性能在较大程度上依赖于条件信息的质量。当条件输入中包含较强噪声或关键信息缺失时，模型难以准确区分有效结构与干扰成分，

从而影响最终的生成质量。因此，如何在不可靠条件下提取稳定有效的引导信息，成为条件扩散模型在实际应用中的重要研究方向。

2.3 书法风格生成基本概念

书法风格生成是字体风格迁移任务在书法艺术领域的特定应用，其目标是：给定一张书法风格参考图像和一张内容参考图像（通常为印刷体或规范字形），生成一张新图像，使得新图像的文字内容与内容参考图像一致，而书写风格（如笔画粗细、墨迹浓淡、笔锋走势、结体特征）与风格参考图像一致。




图 2.2: 书法风格生成基本框架示意图

如图 2.2 所示，现有书法风格生成方法通常遵循“风格与内容解耦”的基本思想。具体而言，模型一般由三个核心模块组成：风格编码器（Style Encoder）、内容编码器（Content Encoder）以及生成器（Generator）。其中，风格编码器用于从风格参考图像中提取反映笔迹特征的风格表示，内容编码器用于从内容参考图像中提取字符结构信息，生成器则融合风格特征与内容特征，在保持内容结构完整性的前提下生成具有指定风格和指定内容目标图像。

与自然图像的风格迁移任务不同，书法风格生成面临更为严格的结构约束。汉字的可读性高度依赖于笔画之间的精确空间关系以及部件组合方式，一旦出现笔画缺失、结构错位或比例失衡，都会显著影响字符的辨识度。因此，该任务需要在“风格表达”与“结构保真”之间实现精细平衡。

在模型发展方面，早期方法多基于生成对抗网络或变分自编码器框架，侧重于风格映射能力的提升。近年来，随着扩散模型在细节建模能力与训练稳定性方面的优势逐渐显现，其被逐步引入字体生成与书法风格迁移任务中，为高质量结构重建与细节生成提供了新的技术路径。

值得注意的是，现有方法通常假设风格参考图像是干净、完整且无退化的。然而，在真实应用场景（如古籍修复）中，风格图像往往存在噪声干扰、残缺或模糊等问题。在此情况下，模型可能将退化信息误识为风格特征，从而导致生成结果出现风格偏移或结构异常。因此，如何在不可靠的风格条件下提取稳定有效的风格表示，成为当前书法风格生成任务中的关键挑战之一。

2.4 本章小结

本章围绕扩散模型相关理论展开，介绍了扩散模型的基本原理，并分析了条件扩散模型在图像修复任务中的一般应用范式，最后对书法风格生成任务的基本概念及其关键问题进行阐述。上述内容为本文后续方法设计提供了必要的理论基础与问题背景。

通过对相关模型机制与任务特点的分析可以看出，如何在复杂退化条件下实现结构信息的有效恢复，并在此基础上实现稳定的风格表达，是当前方法面临的核心挑战。针对上述问题，本文将在后续章节中对扩散模型的具体建模方式及风格生成模块的结构设计进行详细说明，并结合所提出的方法开展系统性实验验证。

第 3 章 古籍汉字专用数据集构建

面向古汉字修复任务的数据集构建需同时兼顾书法风格的多样性、字符覆盖的全面性以及退化模式的真实性，这是支撑模型训练与系统评测的基础前提。

本章首先介绍数据集的整体构成与规模，包括训练集与测试集的划分方式及三种泛化测试场景的设计；其次阐述数据来源与标准化处理流程；详细说明侵蚀痕迹的分级模拟方法，包括侵蚀掩码的获取、难度等级划分与数据增强策略；最后对本章内容进行小结。

3.1 数据集构成

为支持古籍汉字修复与书法风格生成任务，本文构建了一个面向古汉字生成与修复研究的专用数据集。该数据集由训练集与测试集两部分组成，并通过控制书法风格与字符类别的组合关系，构建多种泛化测试场景，从而系统评估模型在不同条件下的生成能力，同时，对于所有的基础图像，我们进行了三种等级的侵蚀痕迹模拟，具体操作将在 3.3 中阐述。本文数据集中的基础图像的风格数量、字符数量及图像规模统计情况如表 3.1 所示。

类型	子集	风格数	字符数	图像数
训练集	—	107	800	85600
测试集	SFUC	13	400	5200
	UFSC	7	800	5600
	UFUC	13	400	5200

表 3.1：数据集基础图像风格与字符统计

数据集基础图像由多种书法风格与常用汉字组合构成，共包含 120 种书法风格与 1200 个常用汉字。其中，书法风格以楷书与行书为主体，同时包含部分隶书及印刷字体风格，以保证字符结构规范性并覆盖多样化的书写风格。字符集合选自《现代汉语常用字表》中的高频汉字，以确保数据集在实际应用中的代表性和实用性。训练集中随机抽取 107 种风格，每种风格对应 800 个常见汉字，通过风格与字符的组合构建，训练集形成大规模的单字图像样本，为模型学习汉字结构特征与书法风格表达提供充足的基础数据。

为评估模型在不同泛化条件下的表现，测试集按照风格(Style)与字符(Character)

是否在训练阶段出现进行组合划分，构建三种不同的测试场景：

风格已见字符未见（SFUC）：在训练阶段已出现的书法风格（13 种）下生成未见汉字（400 字），用于评估模型在已见风格条件下的字符泛化能力；

风格未见字符已见（UFSC）：在未见书法风格（7 种）下生成训练阶段已出现的汉字（800 字），用于评估模型对新书法风格的适应能力；

风格与字符均未见（UFUC）：在风格与字符均未见的情况下进行生成（13 种风格×400 字），用于评估模型在风格与字符同时变化条件下的联合泛化能力。

3.2 数据来源与处理方式

本文数据集的构建综合采用字体渲染数据与真实书法图像数据两类来源，以兼顾数据规模、字符覆盖度与真实书写风格的多样性。

3.2.1 TTF 渲染数据

本文从方正字库官网^[34]收集了 80 种具有书法特征的 TrueType（TTF）字体文件，并利用 Python 脚本对 800 个常用汉字进行批量渲染，生成清晰规范的单字图像。所选字体既包括黑体、宋体、微软雅黑、方正宋体、华文楷体等常见印刷字体，也包括方正曹全碑隶书、方正王献之小楷、方正米芾行书等具有明显书法特征的字体。这类字体样本结构规范、风格稳定，有利于模型学习汉字的基本结构及书写风格特征。

3.2.2 真实碑帖图像

本文采集了 40 种书法风格的真实汉字图像，以增强数据集对真实古籍书写风格的覆盖能力。相关数据主要来源于公开书法图像数据集与互联网公开书法资料两类。其中，部分样本来自现有开源书法图像数据集 ARMCD^[2]、MCCD^[30]、M5HisDoc^[32]等，这些数据集通常提供较为规范的单字图像或碑帖图像，为数据构建提供了稳定的基础样本来源；此外，本文还从互联网公开书法资源中收集古籍善本扫描件、碑帖拓片及书法作品数字化图像等高分辨率资料^[35]，以进一步扩展数据集的风格覆盖范围。

在具体来源上，所采集样本既包括基于代表性碑帖作品整理得到的风格图像，也包括以典型书家书风为核心构建的风格样本。例如，相关图像涵盖《玄妙寺道教三相

殿重建记》、《东方朔画像题赞》、《九成宫醴泉铭》等具有代表性的碑帖作品，并覆盖欧阳询、颜真卿、柳公权、赵孟頫等楷书经典书风以及宋徽宗瘦金书等具有鲜明个人特征的书写风格。通过引入不同历史时期与不同书家体系的书写样式，数据集在风格多样性与代表性方面得到了有效提升。部分真实书法图像示例如图 3.1 所示。



图 3.1：数据集中部分真实书法图像示例

在样本筛选过程中，本文优先选取侵蚀痕迹较轻、字形结构清晰的单字图像，以保证样本质量并降低严重退化对模型训练的干扰。对于部分古籍材料中难以获取完整 800 个常用汉字的情况，本文采用两种方式进行补充：一是在风格一致性可接受的前提下，补充同风格体系下后世临摹或摹写的对应汉字图像；二是对存在噪声或背景干扰的图像进行适度的数字图像处理，以提升样本的可辨识性与可用性。



图 3.2：真实汉字图像统一标准化处理流程

在完成样本筛选与补充后，本文进一步对真实汉字图像进行统一标准化处理，以减小不同来源数据之间的分布差异。实际收集到的古籍单字图像在视觉形式上主要可分为两类：一类为浅色背景（如灰底或黄底）上的黑字图像，另一类为深色背景（如

灰底或黑底）上的白字图像。由于两类图像在前景极性上存在差异，需采用不同的处理路径以实现统一表示。

如图 3.2 所示，针对不同输入形式，本文设计了两条标准化处理流程，并最终将所有图像统一转换为 96×96 像素的白底黑字格式：

对于浅色背景黑字图像，首先进行灰度化处理以去除彩色信息，仅保留亮度结构；随后通过阈值分割提取字符前景，增强笔画与背景之间的对比度；在此基础上，引入形态学去噪方法对二值图像进行处理。具体而言，本文采用开运算（Opening），即先对图像进行腐蚀（Erosion）以去除小尺度噪声点，再进行膨胀（Dilation）以恢复字符主体结构，从而在保留笔画形状的同时有效去除背景干扰。最后对字符区域进行裁剪，并通过等比例缩放与居中填充，将图像标准化为 96×96 像素尺寸。

对于深色背景白字图像，处理流程与上述类似，但在阈值分割之后需额外进行黑白反转操作，将白字黑底图像转换为黑字白底形式，以统一前景表达；随后同样采用形态学开运算进行去噪处理，并完成字符裁剪与尺寸标准化。

通过上述统一处理流程，本文将不同来源、不同背景形式的古汉字图像映射至一致的白底黑字表示空间，从而保证输入模型的数据在尺寸与视觉形式上的一致性。该标准化过程不仅有助于提升模型训练的稳定性，也能够一定程度上减小不同来源样本之间的分布差异。

3.3 侵蚀痕迹模拟

古籍汉字中的侵蚀痕迹与现实图像中的噪声存在本质区别。常见的图像去噪任务处理的多为高斯噪声、椒盐噪声等随机分布的像素级干扰，这类噪声通常服从特定的统计分布且与图像内容无关。而古籍汉字的侵蚀痕迹具有显著的结构性特征，具体表现在以下几个方面：

侵蚀分布的非均匀性与边缘聚集效应：侵蚀痕迹并非均匀覆盖于字符区域，而是呈现出明显的空间选择性。由于笔画边缘区域的物理结构相对薄弱，更容易受到风化、磨损等外力作用的侵蚀，因此侵蚀往往沿着笔画轮廓向内蔓延，形成不规则的缺失区域。这种边缘聚集效应使得侵蚀痕迹与汉字的笔画走向、粗细变化存在内在关联，而非简单的像素级随机扰动。

侵蚀尺度的多层级差异：古籍汉字中的侵蚀痕迹在尺度上呈现出显著的多样性。在微观层面，存在微小的点状剥落与针孔状缺损，这类侵蚀仅影响笔画的局部细节；在中观层面，侵蚀区域沿笔画边缘延伸，形成断续的锯齿状缺失；在宏观层面，部分区域出现大面积的块状剥落，可能导致整个笔画部件或结构节点的完全缺失。不同尺度的侵蚀痕迹往往在同一字符中共存，进一步增加了退化模式的复杂性。

侵蚀边界的形态学复杂性：侵蚀区域的边界形态与理想化的几何形状相去甚远。受石质纹理、纸张纤维分布等介质不均匀性的影响，侵蚀边界通常呈现为锯齿状、毛刺状或不规则曲线状。此外，在大面积侵蚀区域内部，常残留有孤立的笔画碎片或墨迹斑点，形成所谓的“岛状残留”。这些残留区域与主体笔画之间的拓扑关系复杂，为修复任务中的结构推断带来了额外的不确定性。

侵蚀痕迹与笔画结构的信息耦合：与高斯噪声等加性噪声不同，古籍侵蚀痕迹与字符的原始笔画信息之间存在高度耦合。侵蚀区域的形成往往与笔画的走向、墨迹的浓淡、纸张或石质的局部特性密切相关，难以通过简单的减性模型进行剥离。这种耦合关系意味着模型在学习修复映射时，需要同时完成“区分侵蚀与笔画”和“推断缺失结构”两项高度关联的任务。

上述特点使得简单的随机噪声添加难以真实模拟古籍的退化过程。若仅采用高斯噪声或椒盐噪声进行数据增强，生成的退化样本将缺乏真实侵蚀所具有的结构性、尺度多样性与边缘复杂性，无法有效驱动模型学习真实场景下的修复能力。在实际古籍图像中，字迹退化往往伴随纸张老化、墨迹晕染、局部残缺等多种复杂形态，单一噪声模型难以覆盖这类多维度、非均匀的退化特征，也容易导致模型在真实测试集上泛化能力不足、修复效果生硬失真。因此，构建贴近古籍实际退化模式的侵蚀模拟方法，是开展古汉字修复研究的必要前提。

为实现真实的侵蚀效果，本文借鉴了 Li 等人^[2]提出的古籍汉字侵蚀掩码合成方法，并以其公开的侵蚀掩码数据集为基础。该数据集中的掩码图像采用二值表示，其中黑色像素代表侵蚀痕迹，白色像素代表背景区域。为便于后续的分级处理，我们依据每张掩码图中黑色像素的占比，将侵蚀程度划分为三个等级：**easy**（侵蚀面积 $\leq 30\%$ ）、**medium**（ $30\% < \text{侵蚀面积} \leq 60\%$ ）和 **hard**（侵蚀面积 $> 60\%$ ），分别对应轻微、中等和严重的侵蚀情况，每个等级对应 3000 张不同的掩码。图 3.3 展示了相同汉字在不同

难度等级下的侵蚀效果示例。




图 3.3: 干净图像及其在不同侵蚀程度下的合成结果

在生成带侵蚀的古籍汉字图像时，我们采用了随机采样的策略以增强数据的多样性。具体流程如算法 1 所示：

算法 1 合成侵蚀生成算法 (Synthetic Erosion Generation)

输入：干净字符图像 $I \in \mathbb{R}^{96 \times 96 \times 1}$ ，难度等级 $d \in \{easy, medium, hard\}$ ，

掩码集合 $\mathcal{M}_{easy}, \mathcal{M}_{medium}, \mathcal{M}_{hard}$

输出： $I_{ero} \in \mathbb{R}^{96 \times 96 \times 1}$

```

1.  $M \leftarrow RandomSelect(\mathcal{M}_d)$  // 从对应难度的掩码池中随机选取掩码
2.  $M \leftarrow Resize(M, 96, nearest)$  // 调整掩码尺寸以匹配图像大小
3.  $\theta \leftarrow RandomChoice(\{0^\circ, 90^\circ, 180^\circ, 270^\circ\})$ 
4.  $M \leftarrow Rotate(M, \theta)$  // 随机旋转掩码
5. if  $RandomBool(0.5)$ 
6.    $M \leftarrow HFlip(M)$  // 随机水平翻转
7. end if
8. if  $RandomBool(0.5)$ 
9.    $M \leftarrow VFlip(M)$  // 随机垂直翻转
10. end if
11.  $M_{bin} \leftarrow \mathbf{1}(M > 0.5)$  // 二值化：1 表示保留区域，0 表示侵蚀区域
12.  $I_{ero} \leftarrow I \odot M_{bin}$  // 逐像素相乘生成侵蚀效果
13. return  $I_{ero}$ 

```

对于给定的干净汉字图像，首先根据预设难度等级从对应侵蚀掩码池中随机选取一张掩码；随后对其随机施加 90° 、 180° 或 270° 旋转，并以 50% 的概率分别进行水平翻转和垂直翻转，以模拟侵蚀方向的不确定性，同时保持侵蚀面积基本不变；最后将变换后的掩码与原始图像逐元素相乘，将掩码中黑色像素对应位置设置为背景色，从

而生成笔画缺失的侵蚀效果。该分级策略有助于从退化强度维度系统评估模型在不同复杂条件下的鲁棒性。

为避免侵蚀掩码在训练集与测试集之间重复使用而引入潜在的数据泄露问题，本文进一步将原始掩码数据划分为相互独立的训练掩码集合与测试掩码集合。其中，训练阶段仅使用训练掩码集合生成带噪样本，测试阶段则仅使用测试掩码集合构造评估数据，从而保证模型在测试时不会接触到训练阶段已出现的侵蚀模式。

3.4 本章小结

本章构建了一个面向古汉字修复任务的专用数据集。数据集基础图像涵盖 120 种书法风格与对应的 1200 个常用汉字，通过控制风格与字符的组合关系划分了 SFUC、UFSC 和 UFUC 三种泛化测试场景。对于所有基础图像采用分级侵蚀掩码模拟了 easy、medium 和 hard 三个难度等级的退化样本。该数据集同时覆盖风格、字符与退化程度三个维度，为后续修复方法的设计与实验评测提供了结构化的数据基础。

第4章 基于扩散模型的古汉字修复框架

针对真实古籍修复中风格参考图像与退化噪声相互耦合的难题，本章从分布解耦的角度出发，提出一种基于扩散模型的两阶段古汉字修复框架，通过“结构恢复”与“风格生成”的显式分离，实现退化条件下风格信息与内容信息的稳定建模。

本章将介绍整体修复框架的设计思路，阐述两阶段分解的逻辑依据与框架组成；并详细说明侵蚀痕迹去噪模块的模型原理、风格生成模块的基本框架及其与前置去噪模块的衔接方式。

4.1 整体修复框架设计

从概率建模角度来看，古汉字修复本质上是一个在退化条件下进行条件分布建模的问题，其中风格分布与退化噪声分布存在耦合关系，若直接将退化风格图像输入生成模型，模型将在训练过程中同时拟合书法风格分布与退化噪声分布，从而导致特征空间中的分布混叠问题，进而影响风格建模的稳定性与生成结果的可靠性。特别是在古籍修复场景中，风格参考图像通常伴随不同程度的侵蚀、模糊或污渍等退化现象，使得噪声信息与真实书法风格特征相互耦合，进一步加剧了这一问题。

为解决上述问题，本文从分布解耦的角度出发，采用两阶段建模策略，将古汉字修复任务分解为“结构恢复”与“风格生成”两个子过程，实现对风格信息与退化噪声的分离建模。其中，第一阶段侧重于从退化图像中恢复基础结构信息并抑制噪声干扰，第二阶段在噪声受控的条件下进行风格建模与字符生成，从而避免噪声对风格表达的影响。为直观展示本文提出的古汉字修复框架，整体结构如图 4.1 所示。




图 4.1：本文方法总览

如图 4.1 所示,本文方法由侵蚀痕迹去噪模块与风格生成模块两部分组成。其中,侵蚀痕迹去噪模块以退化古汉字图像 $x_{degraded}$ 作为输入,在条件扩散模型框架下,通过 U-Net 网络逐步预测噪声并恢复得到结构完整的干净图像 x_s 。在此基础上,风格生成模块以去噪结果 x_s 作为风格参考图像,并结合内容参考图像 x_c ,分别输入风格编码器 E_s 与内容编码器 E_c ,得到风格嵌入 e_s 与结构特征 F_s 。在扩散生成过程中融合两类特征信息,逐步生成目标古汉字图像 x_0 。此外,引入风格对比细化模块^[29]以增强风格与内容的解耦表示,从而提升生成结果的风格一致性与结构稳定性。

该两阶段框架通过显式分离“结构恢复”与“风格生成”两个过程,有效降低了退化噪声对风格建模的干扰,在保证字符结构合理性的同时提升了风格一致性与生成稳定性,为真实古籍修复场景下的古汉字生成提供了一种可行的解决方案。

4.2 侵蚀痕迹去噪模块

本文提出的侵蚀痕迹去噪方法基于条件去噪扩散概率模型(Conditional Denoising Diffusion Probabilistic Model)框架,在标准 DDPM^[25]的基础上引入退化图像作为条件约束,以引导模型实现对侵蚀区域的结构恢复与细节重建。在前向扩散过程中,逐步向数据样本 $x_{clean} \sim q(x_{clean})$ 添加高斯噪声,经过 T 步后得到接近各向同性高斯分布的纯噪声 $x_T \sim \mathcal{N}(0, I)$ 。反向去噪过程则学习该扩散过程的逆映射,并在每一步以侵蚀退化的古籍汉字图像 $x_{degraded}$ 作为条件输入,对噪声进行逐步校正,从而在 T 步内将随机噪声恢复为结构完整、笔画清晰的目标图像。

相较于传统无条件扩散模型,该方法通过引入退化图像作为条件引导,使模型能够显式感知笔画缺失区域及退化模式,从而有效提升侵蚀区域的结构恢复能力与整体书法风格一致性。

4.2.1 前向扩散过程

在前向过程中,对干净图像 x_{clean} 逐步添加高斯噪声,构建马尔可夫链:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t \mathbf{I}) \quad (4.1)$$

其中, $\{\beta_t\}_{t=1}^T$ 为预定义的噪声调度序列。

通过递推，可以得到从 x_{clean} 到任意时刻 t 的闭式表达：

$$q(x_t|x_{clean}) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_{clean}, (1 - \bar{\alpha}_t)\mathbf{I}) \quad (4.2)$$

其中： $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$;

在训练过程中，时间步 t 从均匀分布 $t \sim \text{Uniform}(1, T)$ 中随机采样。因此可以通过一次采样直接得到：

$$x_t = \sqrt{\bar{\alpha}_t} x_{clean} + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I}) \quad (4.3)$$

在本文中，前向扩散仅作用于干净图像 x_{clean} ，用于构建训练目标，而退化图像 $x_{degraded}$ 不参与加噪过程，仅作为条件输入。

4.2.2 条件反向去噪过程

反向过程旨在从纯噪声 x_T 逐步恢复出目标图像，其建模形式为：

$$p_\theta(x_{t-1}|x_t, x_{degraded}) \quad (4.4)$$

其中，神经网络参数为 θ ，用于预测每一步的去噪方向。在实际建模中，模型预测噪声项 ϵ_θ ：

$$\epsilon_\theta(x_t, t, x_{degraded}) \quad (4.5)$$

则反向过程可写为：

$$p_\theta(x_{t-1}|x_t, x_{degraded}) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t, x_{degraded}), \sigma_t^2 \mathbf{I}) \quad (4.6)$$

其中均值为：

$$\mu_\theta(x_t, t, x_{degraded}) = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t, x_{degraded}) \right) \quad (4.7)$$

通过该形式，模型在每一步利用退化图像提供的结构信息，对噪声进行校正，从而逐步恢复被侵蚀的笔画。

4.2.3 网络结构设计

本文采用 U-Net 结构作为主干网络，并针对古籍汉字修复任务进行适配。模型输入包括三部分：当前噪声图像 x_t 、时间步嵌入 t 、条件图像 $x_{degraded}$ 。

其中，时间步 t 通过正弦位置编码映射为高维特征，并通过特征调制方式注入

U-Net 各层特征表示中。条件图像 $x_{degraded}$ 与噪声图像 x_t 在输入端通过通道拼接（Concatenation）进行融合，联合输入编码器，使模型能够显式感知侵蚀区域的位置分布及结构退化模式，从而引导后续的去噪过程。

在特征表示上，编码器逐层提取多尺度特征，分别记为 h_1, h_2, h_3 ，用于表征不同层级的笔画结构信息；在最深层，得到高层语义特征表示 h_L ，并通过瓶颈层映射为潜在表示 z 。在解码过程中，利用跳跃连接（Skip Connection）将编码阶段的特征 h_i 与对应解码层进行融合，从而实现细节信息的有效恢复。

整体网络结构包括：

Encoder（下采样路径）：逐层提取多尺度特征，增强对笔画结构的建模能力；

Bottleneck（瓶颈层）：整合全局语义信息，区分噪声与真实笔画结构；

Decoder（上采样路径）：逐步恢复空间分辨率，并结合跳跃连接（Skip Connection）融合编码阶段的多尺度特征，以提升细节重建能力；

值得注意的是，本文保持输入与输出分辨率一致（均为 96×96 像素），无需额外上采样操作，从而避免分辨率变化带来的结构失真问题。此外，该结构通过多尺度特征传递，有效提升了对复杂笔画结构与细节信息的建模能力。

4.2.4 损失函数设计

模型训练目标为最小化预测噪声与真实噪声之间的均方误差（MSE Loss）：

$$\mathcal{L}_{MSE} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_\theta(x_t, t, x_{degraded})\|^2] \quad (4.8)$$

在古籍修复任务中，该损失函数通过噪声预测学习完整的生成分布，提高模型泛化能力，在不同噪声尺度下学习笔画结构恢复，并避免直接像素回归导致的模糊问题。

4.3 风格生成模块

本文的风格生成模块基于 FontDiffuser^[29]的基本框架进行构建。FontDiffuser 通过扩散模型实现内容与风格的联合建模，在字体生成任务中能够有效提升细节质量与风格真实性。在具体实现上，该框架通过风格编码器与内容编码器对输入图像进行解耦表示。其中，风格编码器用于提取表征书法风格的嵌入特征，内容编码器用于提取字符结构信息。在扩散生成过程中，模型以内容特征作为结构约束，以风格嵌入作为风

格引导，对随机噪声进行逐步去除，最终生成兼具目标内容与指定风格的汉字图像。为进一步增强风格表达能力，模型在生成过程中引入风格对比精炼机制（Style Contrastive Refinement, SCR^[29]），通过对风格特征施加对比约束，使模型能够在特征空间中更好地区分不同书法风格。然而，该方法通常基于理想条件下的风格参考图像进行建模，默认输入的风格图像为干净且无退化噪声的形式。

但在真实古籍修复场景中，风格参考图像往往同时包含书法风格特征与侵蚀、模糊等退化噪声。若直接将此类退化风格图像输入 FontDiffuser，模型容易将噪声误建模为风格特征，从而影响生成结果的稳定性与风格一致性。基于这一问题，本文并未直接修改该框架的内部生成机制，而是采用两阶段处理策略：在风格生成模块之前，首先引入侵蚀痕迹去噪模块，对退化风格参考图像进行预处理，获得结构较完整、噪声受控的风格输入；随后再将去噪后的风格参考图像输入风格生成模块，在扩散生成框架下完成风格迁移与目标汉字重建。该策略的核心目的在于，在生成之前尽可能实现“风格信息”与“退化噪声”的分离，从而提高风格生成模块在真实古籍退化条件下的适用性与鲁棒性。

为了验证风格生成模型是否能够在无前置去噪的条件下同时学习风格迁移与噪声去除，本文设计了可行性验证实验：在训练集与测试集规模设置均与第 5.4 节相同的前提下，仅将干净风格参考图像替换为带有不同程度侵蚀痕迹的风格参考图像，并直接用于训练风格生成模块。实验旨在探讨单阶段框架是否能够同时完成风格建模与退化噪声抑制。然而，实验结果表明，这一设想并不可行。如表 4.1 所示，直接使用带噪风格图像训练的模型在各数据划分下整体表现均较差，且这一现象在轻度侵蚀条件下同样明显。SFUC-Easy 条件下模型的 FID 为 54.897、SSIM 仅为 0.6793，并且随着侵蚀程度的增加生成质量不断下降。该结果说明，侵蚀噪声对风格建模的干扰具有普遍性，单阶段框架难以在训练过程中同时完成风格迁移与噪声抑制。进一步从可视化结果（图 4.2）可以观察到，生成图像普遍存在黑色噪点残留、边缘不平滑、笔画断裂及字形走形等问题，严重影响了汉字结构完整性与视觉质量。

	Easy				Medium				Hard			
	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1
SFUC	54.897	0.6793	0.3491	0.2191	54.217	0.6814	0.3467	0.2171	79.286	0.6550	0.3735	0.2386
UFSC	69.153	0.6636	0.3675	0.3142	70.808	0.5838	0.3614	0.2988	74.648	0.5942	0.3626	0.2931
UFUC	76.939	0.6793	0.3234	0.2129	77.219	0.6501	0.3471	0.2362	72.780	0.6678	0.3398	0.2268

表 4.1：在带噪声数据集上训练风格生成模块结果



图 4.2：带侵蚀痕迹数据训练下的风格生成结果示例

上述结果说明，训练数据中的侵蚀噪声不会在风格生成过程中被自动有效消除，反而会显著干扰模型对书法风格特征的建模，并在扩散生成过程中被进一步传递甚至放大。因此，仅依赖单阶段生成模型同时完成风格迁移与噪声去除是困难的，前置侵蚀痕迹去噪是必要的。基于此，本文采用“先去噪、后生成”的两阶段框架：首先利用侵蚀痕迹去噪模块净化风格参考图像，再通过风格生成模块完成风格引导下的目标汉字生成。相关结论将在 5.5 节消融实验中结合定量与定性结果进一步验证。

第 5 章 实验设计与结果分析

为系统验证本文提出的两阶段古汉字修复框架的有效性，本章从实验环境配置、数据集划分、评价指标、模块性能、泛化能力及消融分析等多个维度开展全面的实验评估，以定量与定性相结合的方式检验方法在复杂退化条件下的修复性能与鲁棒性。此外，补充任务泛化性实验与定性分析，以进一步论证方法的适用性与稳定性。最后，搭建并展示基于 Streamlit 的 Web 可视化交互界面，直观呈现模型在风格选择、侵蚀去噪到风格迁移生成全流程中的实际修复效果。

5.1 实验环境与参数设置

为保证实验结果的可复现性与不同模块之间的公平对比，本文在统一的硬件与软件环境下完成所有实验，并对侵蚀痕迹去噪模块与风格生成模块分别进行相关参数设置的说明。

5.1.1 实验环境配置

本研究的实验运行环境如下：

类别	项目	配置
软件环境	操作系统	Ubuntu 20.04
	Python 版本	Python 3.8
	深度学习框架	PyTorch 2.0.0
	CUDA 版本	CUDA 11.8
硬件环境	GPU	NVIDIA RTX 4090D（24GB）×1
	CPU	Intel Xeon Platinum 8474C（15 vCPU）
	内存	80G

表 5.1：实验环境配置

所有模型均在上述统一环境下进行训练与推理。

5.1.2 实验数据设置

本文所有实验均基于第 2 章构建的古籍汉字数据集开展。该数据集包含多种书法风格的干净汉字图像及其对应的侵蚀退化版本，能够同时支持图像修复与风格生成两类任务。在具体使用方式上，不同模块采用不同的数据组织形式：

侵蚀痕迹去噪模块：使用数据集中构建的“干净—侵蚀”配对数据进行训练，其数据来源于同一数据集中的侵蚀样本子集。训练集包含从总训练数据集中随机抽取的 10400 对图像，测试集包含从总测试集中随机抽取 5600 对图像。其中，侵蚀样本覆盖不同退化程度（easy、medium、hard），用于模拟古籍中不同程度的损伤情况。

风格生成模块：使用本文构建的数据集中的基础图像进行训练与测试。测试集按照风格与字符是否在训练阶段出现进行划分，构建 SFUC、UFSC 和 UFUC 三种测试场景，以评估模型在不同泛化条件下的生成能力。具体数据规模见第 3 章表 3.1。

需要指出的是，去噪模块与风格生成模块共享同一数据来源，但在任务定义与数据组织方式上存在差异：前者侧重于从退化图像中恢复结构信息，后者侧重于在给定风格条件下生成目标字符图像。这种统一数据体系有助于保证整体框架的一致性，并减少跨任务数据分布差异对实验结果的影响。

5.1.3 参数设置

侵蚀痕迹去噪模块训练参数设置：diffusion 训练步数为 2000，总训练迭代次数为 500000，学习率为 1×10^{-5} ，训练批次大小为 4；在推理阶段，采用 DDPM 标准采样策略，采样步数设为 100，以在生成质量与计算开销之间取得平衡。

风格生成模块训练参数设置：优化器使用 AdamW，训练批次大小为 16；训练过程分为两个阶段：第一阶段的训练步数为 150000，学习率为 1×10^{-4} （线性衰减）；第二阶段的训练步数为 10000，学习率为 1×10^{-5} （固定），同时负样本数为 16。此外，参考相关研究方法，在训练过程中以 0.1 的概率随机丢弃源图像与参考图像，以增强模型的鲁棒性^[29]。在推理阶段，采用 DPM-Solver++ 采样器^[36]，并将采样步数设置为 20，以提高生成效率。

上述实验配置在保证训练稳定性的同时，也兼顾了模型在复杂退化场景下的表达能力，为后续实验提供了统一的实验基础。

5.2 评价指标

为了全面、客观地评估不同修复方法的性能，本文采用多种评价指标，从图像质量、感知相似性及分布一致性等多个维度对模型生成结果进行综合衡量。

结构相似性指数 (SSIM)：用于衡量两幅图像在亮度、对比度及结构信息上的相似程度，能够有效反映图像结构的保持情况。在古汉字修复任务中，该指标对于评估笔画结构与字形布局的重建质量具有重要意义。SSIM 值越高，表示生成结果在整体结构上与真实图像越接近。其定义如下：

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (4.1)$$

其中， x 和 y 分别表示修复图像与真实图像中对应的图像块， μ_x 、 μ_y 为均值， σ_x 、 σ_y 为标准差， σ_{xy} 为协方差， C_1 、 C_2 是为避免除零而设置的常数。

学习感知图像块相似度(LPIPS)：在深度特征空间中衡量两幅图像之间的感知差异，更符合人类视觉系统对图像相似性的判断。该指标通过比较预训练网络（本文使用的是 VGG）中多层特征的距离来评估图像质量，能够有效反映纹理、风格及细节层面的差异。在书法生成与修复任务中，LPIPS 对于衡量笔画质感及风格一致性具有重要参考价值。LPIPS 值越低，表示两幅图像在感知层面越接近。

$$\text{LPIPS}(x, y) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \|w_l \odot (\hat{y}_l^{hw} - y_l^{hw})\|_2^2$$

其中， $\hat{x}^l$ 、 $\hat{y}^l$ 为从预训练网络第 l 层提取并经过单位归一化的特征图， w_l 为用于缩放通道维度的学习权重， H_l 、 W_l 为特征图的空间尺寸， $\odot$ 表示逐元素相乘。

平均绝对误差 (L1 Loss)：L1 损失用于计算生成图像与真实图像之间的像素级差异，其定义为两者对应像素绝对误差的平均值。相比于 L2 损失，L1 损失对异常值更为鲁棒，能够在一定程度上减少过度平滑现象，有助于保持图像边缘与细节信息。在古汉字修复任务中，该指标能够有效衡量笔画重建的精确程度。

$$\mathcal{L}_{L1} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (4.3)$$

其中， y_i 为真实图像的像素值， $\hat{y}_i$ 为修复图像的像素值， N 为图像的总像素数。

Fréchet Inception Distance (FID^[37])：用于衡量生成图像分布与真实图像分布之间的差异。该指标通过计算两组图像在 Inception 网络特征空间中的均值与协方差距离，评估生成结果的整体分布一致性。在书法生成任务中，FID 能够从全局层面反映生成图像在风格表达与真实感方面的质量，是衡量生成模型性能的重要指标之一。FID 值越低，表示生成结果越接近真实数据分布。

$$\text{FID} = \|\mu_r - \mu_g\|_2^2 + \text{Tr}\left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}}\right) \quad (4.4)$$

其中， μ_r 、 Σ_r 为真实图像集在 Inception 网络特征层上的均值与协方差矩阵， μ_g 、 Σ_g 为生成图像集（即修复结果集）对应的均值与协方差矩阵， $\text{Tr}(\cdot)$ 表示矩阵的迹。

在实验中，本文综合采用 SSIM、LPIPS、L1 及 FID 四种指标，从结构一致性、感知质量、像素精度及分布匹配等多个角度对模型性能进行评估。该组合评价体系能够更加全面地反映模型在古汉字修复任务中的生成效果。

5.3 侵蚀痕迹去噪模块效果分析

表 5.2 给出了侵蚀痕迹去噪模块与标准 U-Net 在 5600 对“干净一带噪”图像上的定量测试结果。总体来看，本文提出的去噪模块在不同侵蚀程度下均表现出较好的稳定性与一致性，能够有效恢复字符结构并抑制退化噪声的干扰。在 Easy 条件下，本模块取得了优异的性能（SSIM 为 0.9795，LPIPS 为 0.0650，L1 为 0.0219），各项指标均优于标准 U-Net（SSIM 为 0.9689，L1 为 0.0242）。尽管标准 U-Net 的 LPIPS 略低（0.0615 vs. 0.0650），但其 FID 和 L1 指标均劣于本文模块，表明标准 U-Net 在生成图像的感知分布和像素级重建精度上存在不足。在 Medium 条件下，本文模块的性能保持稳定（SSIM 为 0.9799，L1 为 0.0219），而标准 U-Net 出现显著下降（SSIM 为 0.9604，L1 为 0.0264，LPIPS 上升至 0.0895），说明中等程度的侵蚀已对标准 U-Net 造成较大干扰，其难以有效区分噪声与原始笔画。在 Hard 条件下，本模块仍能维持一定的恢复能力（SSIM 为 0.9591，LPIPS 为 0.0793，L1 为 0.0359），而标准 U-Net 的性能进一步恶化（SSIM 为 0.9512，LPIPS 为 0.0969，L1 为 0.0425），反映出其面对大面积遮盖时的脆弱性。

	Easy				Medium				Hard			
	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1
去噪模块	9.534	0.9795	0.0650	0.0219	9.849	0.9799	0.0657	0.0219	11.799	0.9591	0.0793	0.0359
标准 U-Net	9.681	0.9689	0.0615	0.0242	14.069	0.9604	0.0895	0.0264	16.453	0.9512	0.0969	0.0425

表 5.2：侵蚀痕迹去噪模块与标准 U-Net 在 5600 对“干净一带噪”图像上的测试结果

图 5.1 展示了不同侵蚀程度下的生成结果。对于 Easy 与 Medium 条件，本文模块能够较为完整地恢复字符的笔画结构，生成结果在笔画连贯性与整体形态上与真实图像高度一致。标准 U-Net 虽然在 Easy 条件下对孤立小面积噪声去除效果较好，但在 Medium 条件下，当侵蚀区域稍大并部分遮盖笔画时，其往往无法将噪声与笔画有效

分离，导致输出中出现粘连伪影或笔画断裂。在 Hard 条件下，标准 U-Net 受限于大面积遮盖，输出中残留大量无法区分的模糊痕迹，甚至将部分背景错误恢复为笔画；相比之下，本文模块在缺乏可靠结构信息时，倾向于将不确定区域恢复为背景，表现为局部笔画被“抑制”或趋于空白。这一现象验证了本文模块在高退化条件下的保守生成策略：相比在不确定区域生成可能错误的笔画，更倾向于避免结构性偏差，从而保证整体字形的合理性与一致性。

	Easy			Medium			Hard		
退化图	觀	九	而	觀	九	而	觀	九	而
标准 U-Net	觀	九	而	觀	九	而	觀	九	而
去噪模块	觀	九	而	觀	九	而	觀	九	而
干净图像	觀	九	而	觀	九	而	觀	九	而

图 5.1：侵蚀痕迹去噪模块与标准 U-Net 在三种侵蚀程度下生成结果的可视化

上述实验表明，本文提出的侵蚀痕迹去噪模块在 Easy 条件下能够高质量地恢复字符细节，对于一般小面积的侵蚀痕迹具有显著的去噪效果，这证明了该模块在实际古籍修复场景中的应用价值。后续 5.7 节的任务泛化性实验将通过更多定性结果进一步验证其通用性。然而，我们也必须注意到：在 Hard 这类大范围遮盖的严重退化场景下，该模块仅能保留未被遮挡的笔画片段，输出结果并非完整的汉字结构。这一保守策略虽然避免了错误笔画的生成，但与古籍修复期望得到完整汉字、还原原始信息的根本目标存在差距。

因此，对于本文面向的大范围遮盖修复任务，不能仅依赖前置的去噪模块，而必须采用本文提出的完整修复框架，在去噪基础上进一步利用风格先验与结构补全能力，实现对严重退化区域的有效重建，从而获得符合预期的完整汉字图像。

5.4 多场景泛化性能对比实验

为全面评估所提出方法在不同泛化条件下的性能表现，本文在统一数据集上对本方法与 DA-Font^[20]、VQ-Font^[19]及 IF-Font^[18]三种代表性方法进行对比实验。上述三种方法均为近年来书法风格生成领域的顶会代表性成果，分别代表了不同的技术研究路

线，由于本文任务面向大面积侵蚀条件下的古汉字生成式重建，而非仅针对已有内容的局部去噪或纹理恢复，因此主对比方法主要选择与基于风格参考的字符生成任务更接近的书法风格生成模型，因而具有较强的可比性与参考价值。

为确保实验结果的严谨性、合理性与横向可比性，所有参与对比的模型均采用完全一致的数据划分策略与图像预处理流程，包括统一的图像尺寸、归一化方式与数据增强策略，并在相同硬件计算环境下训练至收敛状态。需要说明的是，对比方法以及本文框架中的风格生成模块均在干净风格参考数据上进行训练，以与现有书法风格生成方法的常规设定保持一致；而本文所引入的侵蚀痕迹去噪模块作为独立子模块，则在带退化噪声的数据上单独训练，用于处理真实古籍场景中受损的风格参考图像。考虑到不同模型在网络结构复杂度、优化目标与收敛速度上存在固有差异，若强行统一训练轮次易导致部分模型未充分优化或过拟合，因此本文未对训练迭代次数进行硬性约束，而是以验证集损失趋于稳定作为模型训练终止的判定标准，从而保证各对比方法均在接近其最优性能的状态下开展公平评估。

在测试阶段，本文分别在 SFUC、UFSC、UFUC 三种典型泛化场景下开展定量与定性测试，并设置 easy、medium、hard 三种逐级递增的侵蚀退化程度，以模拟古籍汉字在实际场景中存在的墨迹残缺、笔画模糊、背景污染等复杂退化情况，综合衡量各模型在复杂干扰下的字形生成精度、风格还原能力与抗退化鲁棒性。各方法的量化对比结果如表 5.3 所示，对应的视觉效果对比则如图 5.2 所示。

		Easy				Medium				Hard			
		FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1
SFUC	DA-Font	26.569	0.6829	0.2235	0.2139	45.668	0.6758	0.2328	0.2287	82.841	0.5964	0.2876	0.2970
	VQ-Font	27.973	0.6806	0.2258	0.2154	49.537	0.6617	0.2443	0.2409	81.483	0.6012	0.2841	0.2929
	IF-Font	49.301	0.6644	0.2032	0.2604	60.432	0.6959	0.2183	0.2411	89.275	0.6233	0.2765	0.2934
	本文方法	12.128	0.7907	0.1340	0.1323	13.257	0.7796	0.1409	0.1391	14.204	0.7690	0.1476	0.1459
UFSC	DA-Font	27.292	0.6612	0.2145	0.2284	47.551	0.5967	0.2510	0.2781	63.415	0.6559	0.2506	0.2826
	VQ-Font	30.329	0.6265	0.2371	0.2564	46.567	0.5962	0.2522	0.2810	58.436	0.5636	0.2826	0.3028
	IF-Font	49.603	0.6181	0.2081	0.2916	63.251	0.7190	0.2072	0.1693	69.414	0.5619	0.2453	0.3530
	本文方法	10.844	0.7498	0.1478	0.1631	10.215	0.7421	0.1521	0.1672	14.463	0.7471	0.1517	0.1649
UFUC	DA-Font	34.870	0.6870	0.2062	0.2079	57.653	0.6647	0.2277	0.2235	64.924	0.5768	0.2768	0.2930
	VQ-Font	37.637	0.6868	0.2077	0.2072	60.166	0.6659	0.2268	0.2226	61.591	0.6805	0.2138	0.2489
	IF-Font	65.027	0.6949	0.2067	0.2100	70.853	0.7061	0.2061	0.2449	87.983	0.5449	0.2284	0.3023
	本文方法	16.932	0.7289	0.1704	0.1766	21.056	0.7175	0.1767	0.1839	22.365	0.7190	0.1788	0.1833

表 5.3：不同泛化场景（SFUC、UFSC、UFUC）下风格生成模型性能对比

在 SFUC 场景中，随着侵蚀程度从 easy 向 hard 逐级提升，对比方法的性能呈现显著下降趋势，FID 指标均出现大幅攀升，DA-Font、VQ-Font、IF-Font 的 hard 条件下 FID 分别达到 82.841、81.483、89.275，较各自 easy 条件分别提升 2.12 倍、1.91

倍、0.81 倍，SSIM 指标则均降至 0.63 以下，说明对比方法在已见风格下面对未见字符的强退化样本时，难以实现稳定的结构重建与风格表达。而本文方法在该场景下各侵蚀程度均保持优异且稳定的性能，三种侵蚀条件下 FID 分别低至 12.128、13.257、14.204，远低于对比方法，SSIM 则均保持在 0.769 以上，LPIPS 与 L1 指标也始终为四类方法中最优，即使在 hard 强侵蚀条件下，LPIPS 仍仅为 0.1476、L1 为 0.1459，体现出方法在已见风格下对未见字符的良好生成能力。

在 UFSC 场景中，对比方法的性能表现出明显的不稳定性，DA-Font 与 VQ-Font 在 medium 条件下 SSIM 分别降至 0.5967、0.5962，IF-Font 则在 hard 条件下 L1 指标骤升至 0.3530，反映出对比方法对未见书法风格的适配能力不足，易受风格分布偏移与退化噪声的双重影响。本文方法在该场景下展现出最优的风格泛化能力，medium 条件下 FID 达到全实验最优值 10.215，且各侵蚀程度下指标波动极小，hard 条件下 FID 仅为 14.463，SSIM 仍保持 0.7471，LPIPS 与 L1 指标均稳定在 0.15~0.17 区间，说明方法通过去噪模块与解耦建模，能够有效提取未见风格的核心特征，实现风格与内容的精准融合。

在 UFUC 场景中，由于风格与字符均为模型训练阶段未接触的分布，该场景对模型的联合泛化能力要求最高，对比方法的性能均出现不同程度的恶化，IF-Font 在 hard 条件下 FID 高达 87.983、SSIM 仅 0.5449，DA-Font 与 VQ-Font 的各项指标也均表现出明显劣势。本文方法在该高难度泛化场景下，仍保持了远超对比方法的性能表现，easy、medium、hard 条件下 FID 分别为 16.932、21.056、22.365，较对比方法最优值仍降低 50%以上，SSIM 均稳定在 0.717 以上，LPIPS 与 L1 指标也显著优于对比方法，证明本文方法在风格与字符双重分布偏移的复杂场景中，仍能有效实现退化噪声抑制、结构精准重建与风格一致性表达，具备较强的联合泛化能力。

整体来看，对比方法的性能均随侵蚀程度提升与泛化难度增加呈现明显下降趋势，核心原因在于其未对风格参考中的退化噪声进行针对性处理，易将噪声误建模为风格特征，导致在分布偏移与退化噪声叠加的场景中建模失效，进一步加剧了模型在复杂条件下的性能退化问题。而本文方法通过两阶段扩散修复框架，侵蚀痕迹去噪为风格生成提供了干净稳定的参考特征，解耦建模则保证了结构与风格的精准融合，从而在不同数据分布与退化程度下均具备更强的适应能力，因此在各类泛化场景与不同侵蚀

程度下，均能保持稳定且优异的修复性能，在结构保持、风格一致性与抗噪声干扰方面均显著优于对比方法。

		Easy		Medium		Hard	
SFUC	退化图像	啊	衛	為	降	和	歡
	DA-Font	火	汉	游	息	簇	冷
	VQ-Font	火	汉	游	息	簇	冷
	IF-Font	火	汉	游	息	簇	冷
	本文方法	火	汉	游	息	簇	冷
	目标图像	火	汉	游	息	簇	冷
UFSC	退化图像	鵲	尤	汉	字	鄺	被
	DA-Font	马	修	斋	隰	鄺	被
	VQ-Font	马	修	斋	隰	鄺	被
	IF-Font	马	修	斋	隰	鄺	被
	本文方法	马	修	斋	隰	鄺	被
	目标图像	马	修	斋	隰	鄺	被
UFUC	本文方法	過	雷	痕	麼	玉	妙
	DA-Font	珩	曦	痕	甌	粥	烏
	VQ-Font	珩	曦	痕	甌	粥	烏
	IF-Font	珩	曦	痕	甌	粥	烏
	本文方法	珩	曦	痕	甌	粥	烏
	目标图像	珩	曦	痕	甌	粥	烏

图 5.2：不同泛化场景（SFUC、UFSC、UFUC）下风格生成模型生成效果对比

从图 5.2 的可视化结果可更直观地看出不同方法在结构保持与风格表达上的差异。结构方面，随侵蚀程度增加，对比方法生成的字符出现笔画断裂、结构错位、边缘不

连续等问题，hard 条件下部分方法甚至无法保持完整字形。而本文方法在不同侵蚀条件下均能维持字符的整体布局与笔画连贯性，避免明显结构性失真，保障了基础可读性。风格表达方面，对比方法易受风格参考中的残留噪声干扰，产生局部噪点、纹理异常或笔画扩散，使整体风格呈现“污染”状态。相比之下，本文方法能有效抑制噪声影响，在笔画粗细、墨迹分布及风格一致性上更接近目标图像。在 hard 条件下，个别区域可能出现轻微边缘粗糙，但整体结构与风格仍保持一致，未出现噪声放大或结构错乱，体现了模型“结构优先、细节保守”的稳健生成策略。

综合定量结果与可视化分析可以看出，本文方法在不同泛化场景与退化条件下均表现出更好的稳定性与一致性。这一结果进一步验证了所提出两阶段框架在退化条件下进行结构与风格解耦建模的有效性。

5.5 消融实验

为验证侵蚀痕迹去噪模块在整体框架中的作用，本文设计了多种消融实验，在 SFUC、UFSC 和 UFUC 三种泛化场景下对比“有侵蚀痕迹去噪模块”与“无侵蚀痕迹去噪模块”两种设置的生成效果。其中，Baseline 指不引入侵蚀痕迹去噪模块、直接使用带退化噪声的风格参考图像输入风格生成模块的单阶段生成方案。需要说明的是，由于实验中风格生成模块基于 FontDiffuser 框架构建，其内部结构与训练机制基本不变，消融分析仅聚焦于侵蚀痕迹去噪模块及两阶段建模策略的贡献，未对风格生成模块内部进行进一步拆分。通过该消融实验，可定量评估去噪模块在不同泛化条件与退化程度下对修复质量的独立影响。实验结果如表 6 与图 10 所示。

模块		Easy					Medium					Hard				
	去噪	生成	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1	FID	SSIM	LPIPS	L1		
SFUC	×	√	18.565	0.7254	0.1828	0.1740	25.910	0.7405	0.1708	0.1646	116.823	0.5455	0.3361	0.3422		
	√	√	13.257	0.7796	0.1409	0.1391	12.128	0.7907	0.1340	0.1323	14.204	0.7690	0.1476	0.1459		
UFSC	×	√	16.783	0.7177	0.1734	0.1880	27.131	0.6352	0.2200	0.2493	57.129	0.7169	0.1926	0.1733		
	√	√	10.844	0.7498	0.1478	0.1631	10.215	0.7421	0.1521	0.1672	14.463	0.7471	0.1517	0.1649		
UFUC	×	√	27.945	0.7037	0.1928	0.1970	63.746	0.6222	0.2613	0.2626	67.341	0.5773	0.2756	0.2901		
	√	√	16.932	0.7289	0.1704	0.1766	21.056	0.7175	0.1767	0.1839	22.365	0.7190	0.1788	0.1833		

表 5.4: 不同泛化场景（SFUC、UFSC、UFUC）下有无侵蚀痕迹去噪模块生成效果对比

从表 5.4 可以看出，在所有泛化场景（SFUC、UFSC、UFUC）及不同侵蚀程度

下，引入去噪模块后，各项指标均得到明显提升。在 SFUC 场景中，Baseline 在 hard 条件下的 FID 高达 116.823，而引入去噪模块后显著降低至 14.204，下降幅度极大。同时，SSIM 由 0.5455 提升至 0.7690，LPIPS 由 0.3361 下降至 0.1476，说明去噪模块能够有效提升结构一致性并减少感知误差。在 easy 与 medium 条件下也呈现出类似趋势，例如 easy 条件下 FID 由 18.565 降低至 13.257，表明即使在轻度侵蚀情况下，去噪模块仍然能够带来稳定收益。在 UFSC 场景中，去噪模块同样显著提升模型性能。例如在 medium 条件下，FID 由 27.131 下降至 10.215，SSIM 由 0.6352 提升至 0.7421，表明在未见风格条件下，去噪模块有助于模型更准确地提取风格特征。在更具挑战性的 UFUC 场景中，Baseline 性能下降更为明显，而本文方法仍保持稳定表现。例如在 hard 条件下，FID 由 67.341 下降至 22.365，LPIPS 由 0.2756 下降至 0.1788，说明去噪模块在复杂泛化场景中对提升模型鲁棒性具有关键作用。总体来看，去噪模块在不同场景与不同退化程度下均带来稳定且显著的性能提升，在强侵蚀条件下效果更加明显。

从图 5.3 的可视化结果可以直观观察到去噪模块对生成质量的影响。在 Baseline 设置下，由于风格参考图像中仍包含大量侵蚀噪声，模型在生成过程中容易受到干扰，导致生成结果出现笔画变粗、边缘不平滑以及局部噪点等问题，尤其在 medium 与 hard 条件下表现更加明显。相比之下，引入去噪模块后，风格参考图像中的侵蚀干扰被有效削弱，使得模型能够更专注于提取真实的风格特征。从结果上看，本文方法在三种侵蚀程度下均能够生成结构清晰、笔画连贯的字符图像。在 easy 与 medium 条件下，生成结果与目标图像基本一致；在 hard 条件下，尽管个别细节仍存在一定差异，但整体结构与风格保持稳定，未出现明显的噪声放大或结构畸变现象。

	SFUC			UFSC			UFUC		
	Easy	Medium	Hard	Easy	Medium	Hard	Easy	Medium	Hard
退化图像									
Baseline									
本文方法									
目标图像									

图 5.3：去噪模块对风格生成结果影响的消融实验可视化对比

结合上述结果可以看出，侵蚀痕迹去噪模块的核心作用在于为风格生成模块提供更加干净且结构一致的风格参考图像。当直接使用带侵蚀的图像作为输入时，噪声信息会与真实风格特征混杂，干扰模型对风格的学习与表达；而通过去噪处理后，风格信息得到有效保留，噪声干扰被抑制，从而使生成结果在结构与风格上更加稳定。

5.6 补充定性分析

本节作为补充定性分析，旨在直观展示不同模型在古汉字风格生成任务中的表现差异，不作为严格的定量对比实验。需要指出的是，所选通用大模型（如豆包、ChatGPT）并未针对该任务进行专门训练，其输入形式与训练范式与本文方法存在差异，因此本实验结果主要用于分析该任务在复杂退化条件下的挑战性以及通用模型在该场景下的适用性边界，而非进行严格的性能优劣比较。具体而言，选取本文方法与通用大模型（豆包、ChatGPT）进行对比，输入统一提示词：“第一张文字图作为风格参考图像，图像上带有侵蚀痕迹，第二张文字图是内容图像，请从排除侵蚀痕迹的干扰从第一张图中学习字体的风格，根据第二张图指定的内容生成带有第一张图字体风格的汉字”。实验结果如图 5.4 所示。

	Easy		Medium		Hard	
退化图像						
豆包						
ChatGPT						
本文方法						
目标图像						

图 5.4：通用大模型与本文所提方法生成结果的可视化对比

从图 5.4 的可视化结果可以看出，不同方法在风格建模与结构保持方面呈现出明显差异。总体而言，本文方法在三种侵蚀程度（easy、medium、hard）下均能够较好地兼顾风格一致性与字符结构完整性，生成结果表现出较好的稳定性。对于通用大模型而言，其生成结果在含噪风格输入条件下表现出一定局限性。以豆包模型为例，在

medium 与 hard 条件下，生成结果中出现明显的非结构性纹理或笔画扩散现象，对于带大面积覆盖的风格参考图像，模型并不能很好地排除噪声的干扰，对于风格的提取能力也有局限性。这一现象表明，通用模型在处理退化风格参考时，难以有效区分“真实风格特征”与“退化噪声成分”，从而在生成过程中将噪声一并建模进结果中，导致风格表达受到污染。相比之下，ChatGPT 在结构建模方面表现出更大的不稳定性。在部分样例中，其生成字符在笔画形态或空间布局上与目标字符存在明显偏差，同时在风格表达上未能充分体现参考图像的笔画特征。这说明在缺乏针对性结构约束与风格建模机制的情况下，通用模型难以同时满足“结构正确性”与“风格一致性”的双重要求。

综上所述，在本任务设定下，本文方法在风格一致性与结构稳定性方面表现出更好的适配性，尤其在含噪风格输入条件下具有更强的鲁棒性。这一结果从侧面表明，在真实古籍修复场景中，仅依赖通用生成模型难以获得稳定结果，而针对任务特性进行结构化建模是提升性能的关键途径。

5.7 任务泛化性实验

为了进一步考查侵蚀痕迹去噪模块在更广泛场景下的适用性，本文将该模块从完整的修复框架中单独剥离，在 Easy 退化条件下对不同风格的汉字进行了去噪测试。

图 5.5 展示了 6 个代表性汉字的去噪效果。




图 5.5: Easy 退化条件下 6 种风格汉字去噪结果

可以看出，该模块能够稳定地去除小面积侵蚀噪声，同时完整保留原始笔画的精细结构与字形特征。无论是对笔画稀疏的简单字，还是对结构繁复的复杂字，模块均表现出良好的泛化能力：生成图像中无明显噪声残留，笔画边缘清晰，未引入结构性伪影。这一结果说明，本文提出的侵蚀痕迹去噪模块不仅在主任务所针对的退化场景

下有效，在一般性的轻度侵蚀修复任务中也具备较强的适应性与实用价值。

5.8 可视化交互界面展示

为了直观展示本文所提古汉字修复模型的实际应用效果，同时为后续研究提供便捷的交互工具，本文基于 **Streamlit** 框架构建了一个轻量级 **Web** 可视化交互界面。该界面封装了第 4 章所提出的两阶段扩散修复模型，支持用户以图形化方式完成“风格图片选择、侵蚀去噪、风格迁移生成”的完整修复流程。



图 5.6: 古汉字修复 Web 可视化界面截图

如图 5.6 所示，界面整体采用三列布局设计，功能分区清晰：

左侧区域（风格图片）：用户从侧边栏选择待修复的退化风格图像（含侵蚀痕迹的古汉字图片），选中后该区域展示原始输入图像。

中间区域（去噪结果）：用户点击“去噪”按钮后，系统调用训练完成的去噪扩散模型（见 4.2 节）对风格图片进行结构恢复与噪声抑制，生成修复后的干净风格图像，并展示于该区域。

右侧区域（生成结果）：用户点击“生成”按钮后，系统结合中间区域去噪后的风格图片与侧边栏选择的内容图片（目标汉字结构），调用风格迁移模块（见 4.3 节）完成古汉字修复与书法风格生成，最终结果展示于该区域。

此外，界面底部设有状态信息文本框，实时反馈模型运行进度与结果保存路径。

每个图像区域均配备“保存图片”按钮，用户可将中间或右侧的生成结果一键保存至本地指定目录

该界面的主要特点包括：

端到端交互体验：用户无需编写任何代码，仅通过点击按钮即可完成从输入到输出的完整修复流程，显著降低了模型的使用门槛。

实时状态反馈：通过底部文本框与前端弹窗提示，用户可清晰了解当前处理阶段（模型加载、去噪处理、风格生成等）与任何可能的错误信息。

结果持久化存储：所有生成的去噪图像与风格迁移图像均自动保存至服务器指定文件夹，并支持一键保存功能，便于后续分析与批量处理。

模块化设计：界面后端基于 Streamlit 框架实现前端展示与后端逻辑的解耦，模型推理部分与交互部分相互独立，便于后续功能扩展与模型迭代。

通过该可视化界面，本文方法的核心能力得以直观呈现。用户可自由选择不同侵蚀程度（easy、medium、hard）的风格图片与不同内容图片，观察模型在各种条件下的修复效果。该界面不仅为论文所提方法提供了可交互的成果展示，也为后续古汉字修复技术的实际应用探索了可行路径。

第 6 章 总结与展望

6.1 主要研究工作总结

本文针对真实古籍修复场景中存在的**数据稀缺、风格参考受损、评测体系不完善**三大核心问题，聚焦古汉字修复的实际需求，从**专用数据集构建、修复方法设计、场景化评测方案**搭建三个维度开展系统性研究，形成了一套适配复杂退化条件的古汉字智能修复解决方案，主要研究工作与成果总结如下：

构建面向古汉字修复的专用数据集：本文构建了一个面向古汉字修复任务的专用数据集，基础图像涵盖了 120 种书法风格和 1200 个常见汉字，并基于侵蚀模拟构建了 easy、medium 和 hard 三种难度等级的退化样本。同时设计了 SFUC、UFSC 和 UFUC 三种具有代表性的泛化测试场景。实验结果表明，该数据集能够有效支撑模型在不同分布条件下的系统评估，为古汉字修复任务的标准化研究提供了可靠的数据基础。

提出基于分布解耦的两阶段古汉字修复框架：针对风格参考图像中退化噪声与书法风格特征耦合的关键问题，本文从分布建模角度出发，将古汉字修复问题形式化为风格分布与退化噪声分布的解耦问题，提出一种两阶段扩散修复框架。该框架通过前置侵蚀痕迹去噪模块实现退化图像的结构恢复与噪声抑制，为后续风格建模提供干净稳定的参考；再通过风格生成模块融合风格编码与内容编码特征，实现目标汉字的结构精准重建与书法风格有效迁移，从根本上降低了退化噪声对风格学习的干扰。实验结果验证了该方法的优越性，在 SFUC 场景 hard 强侵蚀条件下，本文方法 FID 值仅为 14.204，显著优于 DA-Font 的 82.841；在 UFSC 场景 medium 条件下 FID 值低至 10.215，为所有对比方法最优，充分证明方法在复杂退化与分布偏移条件下的有效性与稳定性。

设计贴近真实场景的评测方案：本文围绕古汉字修复的实际需求，构建了多维度、场景化的模型评测体系：在“三种泛化场景+三类侵蚀程度”的复合实验设置下，采用 FID、SSIM、LPIPS、L1 四项指标，从分布一致性、结构相似性、感知质量、像素精度四个维度对模型性能进行量化评估；同时通过消融实验验证了侵蚀痕迹去噪模块在稳定风格建模、提升修复效果中的核心作用，并结合可视化结果完成定性分析，实现了对模型性能的全面、客观评价。该评测方案贴合真实古籍修复的复杂场景，为

古汉字修复模型的性能验证提供了可参考的标准范式。

搭建可视化交互展示系统:为直观验证本文方法的实际修复效果并降低使用门槛,本文基于 Streamlit 框架搭建了可视化交互界面。该界面封装了所提出的两阶段扩散修复模型,支持用户以图形化方式完成风格图片选择、侵蚀痕迹去噪及风格迁移生成的完整操作流程,并实时反馈处理状态与结果。通过该界面,可直观对比原始退化图像、去噪后图像与最终修复结果,为本文方法在复杂退化条件下的结构保持与风格表达能力提供了可视化的实证支撑。

综合来看,本文从数据、方法、评测三个层面搭建了面向真实古籍修复场景的研究体系,尝试以分布解耦的建模思路探索退化风格参考下的古汉字修复问题。实验结果表明,所提方法能够在复杂退化条件下较好地平衡古汉字的结构恢复与风格一致性要求,在多种泛化场景中具备一定的稳定性与鲁棒性,同时通过可视化界面直观呈现了模型的全流程修复能力,可为古汉字智能修复技术的后续研究与实践应用提供些许参考,也希望能为书法风格生成技术在文物数字化保护领域的落地探索提供一些思路。

6.2 研究局限性分析

尽管本文方法在古汉字修复任务中取得了一定效果,但仍存在以下局限性:

对复杂连笔书法风格的建模能力仍有限:本文方法主要基于单字级别进行建模,在处理结构相对清晰的楷书及部分行书风格时表现较好。然而,对于高度连笔、笔画交错复杂的书法风格(如草书或强连笔行书),模型在笔画分离与结构还原方面仍存在一定困难,生成结果可能出现结构模糊或局部失真现象,表明当前模型对复杂书写结构的表达能力仍有待提升。

在极端退化条件下的鲁棒性仍需增强:在 hard 难度条件下,当原始字符结构受到严重破坏时,去噪模块难以完全恢复有效的结构与风格信息,导致后续生成结果在局部细节上仍存在一定偏差。这表明当前方法在极端退化场景下的稳定性与恢复能力仍有进一步提升空间。

尚未扩展至文本级与版面级修复任务:本文主要聚焦于单字符修复问题,未涉及多字符连续排布的文本级修复任务。在真实古籍修复场景中,字符之间往往存在行间结构、排版布局及风格连续性等约束,当前方法尚未对这些跨字符关系进行建模。

6.3 未来研究方向展望

针对上述局限性，未来可以从以下几个方向进一步开展研究：

提升复杂书法风格的结构建模能力：未来可引入更加细粒度的结构建模机制，例如结合笔画级表示、拓扑结构约束或结构先验信息，以提升模型对连笔书法及复杂字形的表达能力，从而增强生成结果的结构合理性与艺术表现力。

增强模型在极端退化条件下的鲁棒性：针对重度侵蚀场景，可进一步优化去噪与生成过程，例如引入更强表达能力的扩散模型、分阶段渐进修复策略或多尺度信息融合机制，以逐步恢复字符结构并提升整体的生成质量。

拓展至文本级与版面级修复任务：未来研究可从单字符扩展至整行甚至整页文本的修复，结合版面分析与结构建模方法，实现字符间风格一致性与布局合理性的统一建模，从而更好地服务于真实场景下的古籍修复应用。

参考文献

- [1] Wang Z, Li Y, Li H. Chinese inscription restoration based on artificial intelligent models[J]. npj Heritage Science, 2025, 13(1): 326.
- [2] Li H, Du C, Jiang Z, et al. Towards automated Chinese ancient character restoration: a diffusion-based method with a new dataset[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(4): 3073-3081.
- [3] Zhu S, Xue H, Nie N, et al. Reproducing the past: a dataset for benchmarking inscription restoration[C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 7714-7723.
- [4] Criminisi A, Pérez P, Toyama K. Region filling and object removal by exemplar-based image inpainting[J]. IEEE Transactions on image processing, 2004, 13(9): 1200-1212.
- [5] Hanif M, Tonazzini A, Savino P, et al. Sparse representation based inpainting for the restoration of document images affected by bleed-through[C]//Proceedings. MDPI, 2018, 2(2): 93.
- [6] Xu Z, Zhang X, Chen W, et al. A review of image inpainting methods based on deep learning[J]. Applied sciences, 2023, 13(20): 11189.
- [7] Lo S W, Chou H M. Joint variation and ZhuYin dataset for Traditional Chinese document enhancement[J]. Scientific Data, 2024, 11(1): 1295.
- [8] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems 27. 2014: 2672-2680.
- [9] Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1125-1134.
- [10] Feng R. CycleGAN with auxiliary classifier for chinese calligraphy style transfer and font classification[J]. Theoretical and Natural Science, 2023, 18: 167-173.
- [11] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.
- [12] Yang Z, Bai H, Luo Z, et al. PaCaNet: A study on CycleGAN with transfer learning for diversifying fused Chinese painting and calligraphy[J]. arXiv preprint

- arXiv:2301.13082, 2023.
- [13]Luo Y, Bi X. MFNet: Multiscale fusion network for Dongba character image inpainting[J]. Expert Systems with Applications, 2025, 294: 128744.
 - [14]Mao Q, Li J, Zhou H, et al. ALDII: Adaptive Learning-based Document Image Inpainting to enhance the handwritten Chinese character legibility of human and machine[J]. Neurocomputing, 2025, 616: 128897.
 - [15]Park S, Chun S, Cha J, et al. Few-shot font generation with localized style representations and factorization[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(3): 2393-2402.
 - [16]Tang L, Cai Y, Liu J, et al. Few-shot font generation by learning fine-grained local styles[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 7895-7904.
 - [17]Wang C, Zhou M, Ge T, et al. Cf-font: Content fusion for few-shot font generation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 1858-1867.
 - [18]Chen X, Ke X, Guo W. IF-font: Ideographic description sequence-following font generation[J]. Advances in Neural Information Processing Systems, 2024, 37: 14177-14199.
 - [19]Yao M, Zhang Y, Lin X, et al. Vq-font: Few-shot font generation with structure-aware enhancement and quantization[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(15): 16407-16415.
 - [20]Chen W, Zhu G, Li Y, et al. DA-Font: Few-Shot Font Generation via Dual-Attention Hybrid Integration[C]//Proceedings of the 33rd ACM International Conference on Multimedia. 2025: 6644-6653.
 - [21]Chen J, Huang Y, Lv T, et al. Textdiffuser-2: Unleashing the power of language models for text rendering[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 386-402.
 - [22]Wu C, Li J, Zhou J, et al. Qwen-image technical report[J]. arXiv preprint arXiv:2508.02324, 2025.
 - [23]Mayr M, Dreier M, Kordon F, et al. Zero-shot paragraph-level handwriting imitation with latent diffusion models[J]. International Journal of Computer Vision, 2025, 133(10): 7054-7075.

-
- [24]Xu T, Wang K, Chen Z, et al. UniCalli: A Unified Diffusion Framework for Column-Level Generation and Recognition of Chinese Calligraphy[J]. arXiv preprint arXiv:2510.13745, 2025.
 - [25]Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.
 - [26]Saharia C, Ho J, Chan W, et al. Image super-resolution via iterative refinement[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(4): 4713-4726.
 - [27]Lugmayr A, Danelljan M, Romero A, et al. Repaint: Inpainting using denoising diffusion probabilistic models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 11461-11471.
 - [28]Bansal A, Borgnia E, Chu H M, et al. Cold diffusion: Inverting arbitrary image transforms without noise[J]. Advances in Neural Information Processing Systems, 2023, 36: 41259-41282.
 - [29]Yang Z, Peng D, Kong Y, et al. Fontdiffuser: One-shot font generation via denoising diffusion with multi-scale content aggregation and style contrastive learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2024, 38(7): 6603-6611.
 - [30]Zhao Y, Zhang Y, Jin L. MCCD: A Multi-attribute Chinese Calligraphy Character Dataset Annotated with Script Styles, Dynasties, and Calligraphers[C]//International Conference on Document Analysis and Recognition. Cham: Springer Nature Switzerland, 2025: 538-555.
 - [31]Zhang Y, Shi Y, Zhang P, et al. MegaHan97K: A large-scale dataset for mega-category Chinese character recognition with over 97K categories[J]. Pattern Recognition, 2025, 167: 111757.
 - [32]Shi Y, Liu C, Peng D, et al. M5HisDoc: A large-scale multi-style Chinese historical document analysis benchmark[J]. Advances in Neural Information Processing Systems, 2023, 36: 78483-78495.
 - [33]Zhu S, Xue H, Nie N, et al. Reproducing the past: a dataset for benchmarking inscription restoration[C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 7714-7723.
 - [34]北京北大方正电子有限公司。方正字库 [EB/OL]. (2025-09-03)[2026-03-16].

<https://www.foundertype.com/>.

[35]雅昌艺术网。历代名家书法碑帖拓片资源 [EB/OL]. (2023-08-28)[2026-03-16].

http://www.yac8.com/news/list_146.html.

[36]Lu C, Zhou Y, Bao F, et al. Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models[J]. Machine Intelligence Research, 2025, 22(4): 730-751.

[37]Heusel M, Ramsauer H, Unterthiner T, et al. GANs trained by a two time-scale update rule converge to a local Nash equilibrium[C]//Advances in Neural Information Processing Systems 30. 2017: 6626-6637.

致 谢

行文至此，落笔为终。本科四年的求学时光，在字斟句酌间悄然接近尾声。论文的完成，不仅是一段学习历程的总结，更是一次自我梳理与成长的见证。

衷心感谢我的指导老师王进。从研究方向的确立到论文的反复修改，老师以专业的学识与温和的态度，为我答疑解惑、指引方向，让我在学术探索中少走弯路，也更懂得严谨与踏实的意义。

感谢苏州大学四年的栽培与滋养，校训“养天地正气，法古今完人”时刻勉励我修身治学、笃行不怠。母校的一草一木、一师一友，都成为青春里最珍贵的印记，也为我即将开启的研究生深造之路筑牢根基。

感谢士鹏师兄在论文写作过程中悉心指导、耐心答疑，为我拨开迷雾、指明方向。感谢始终不服输的自己，在一次次挫折与困顿里，依然选择坚定向前、未曾放弃。感谢家人始终默默守护，用最朴素的支持，给予我最坚定的力量。同时感谢钊宏老师，你的优秀作品陪伴我度过了无数枯燥平淡的时光，给予我精神上的慰藉与力量。更感谢小菜园，让我在外求学的日子里，仍能尝到熟悉的家乡滋味。感谢同窗好友一路同行，在交流中碰撞思路，在困顿中相互支撑，让平凡的日常多了许多温暖与光亮。

本科篇章至此落笔，学术求索未有穷期，前路漫漫，继续笃行。